

# Záverečný projekt

Lukáš Gaľa

# Ciel' projektu

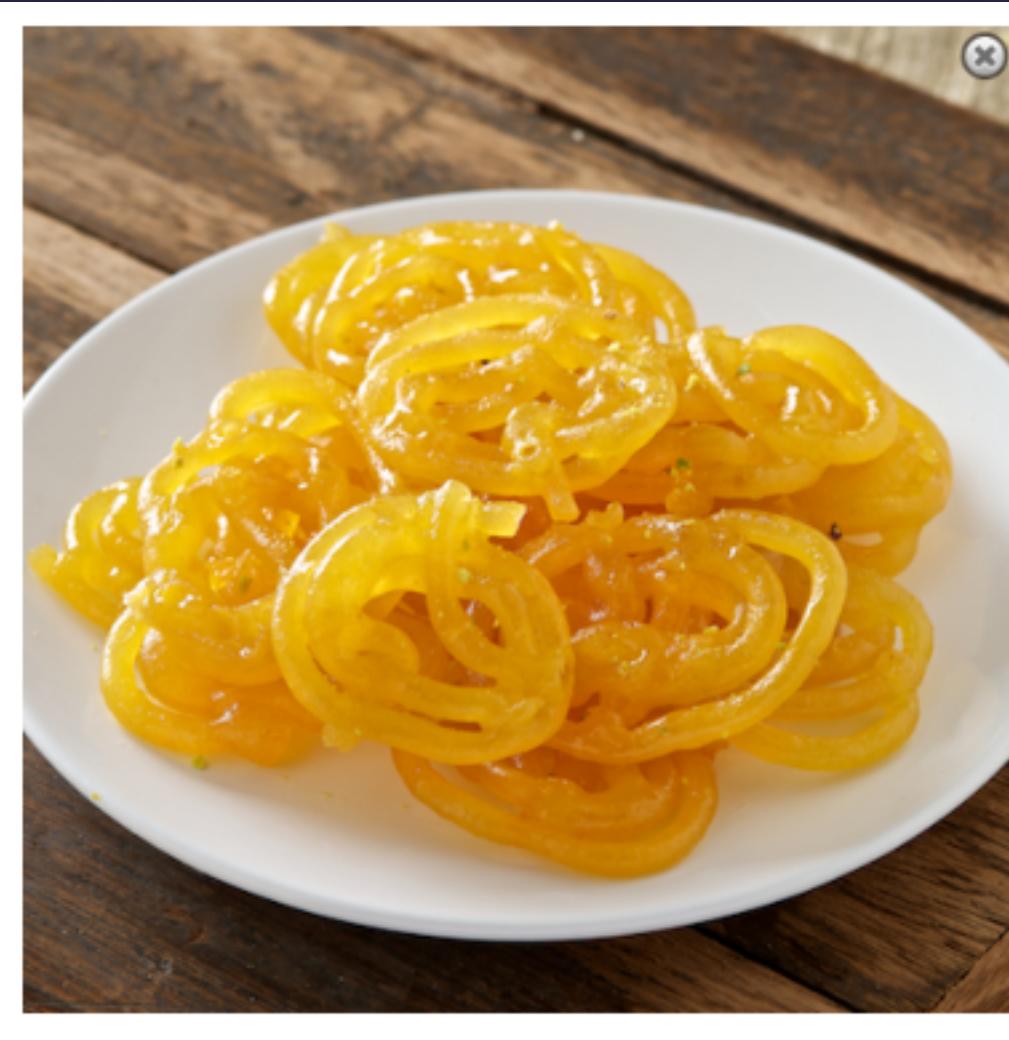
- Nájst' optimálny model na klasifikáciu zadaného datasetu
- Klasifikovaný dataset: Food Image Classification
- Zdroj datasetu:
- <https://www.kaggle.com/datasets/gauravduttakiit/food-image-classification>

# Štruktúra datasetu

- Počet tried (labelov) v datasete: 34 tried
- Príklady:
- 'samosa', 'sushi', 'burger', 'idli', 'omelette', 'dal\_makhani', 'chapati',  
'ice\_cream', 'Sandwich', ,apple\_pie‘, Crispy Chicken',  
'chole\_bhature', 'pakode', 'Taco', 'butter\_naan', 'kulfi', 'Donut',  
'momos', 'cheesecake'

# Štruktúra datasetu

- Celkový počet obrázkov: 23 873
- Príklady  
„Jalebi“



# Preprocessing

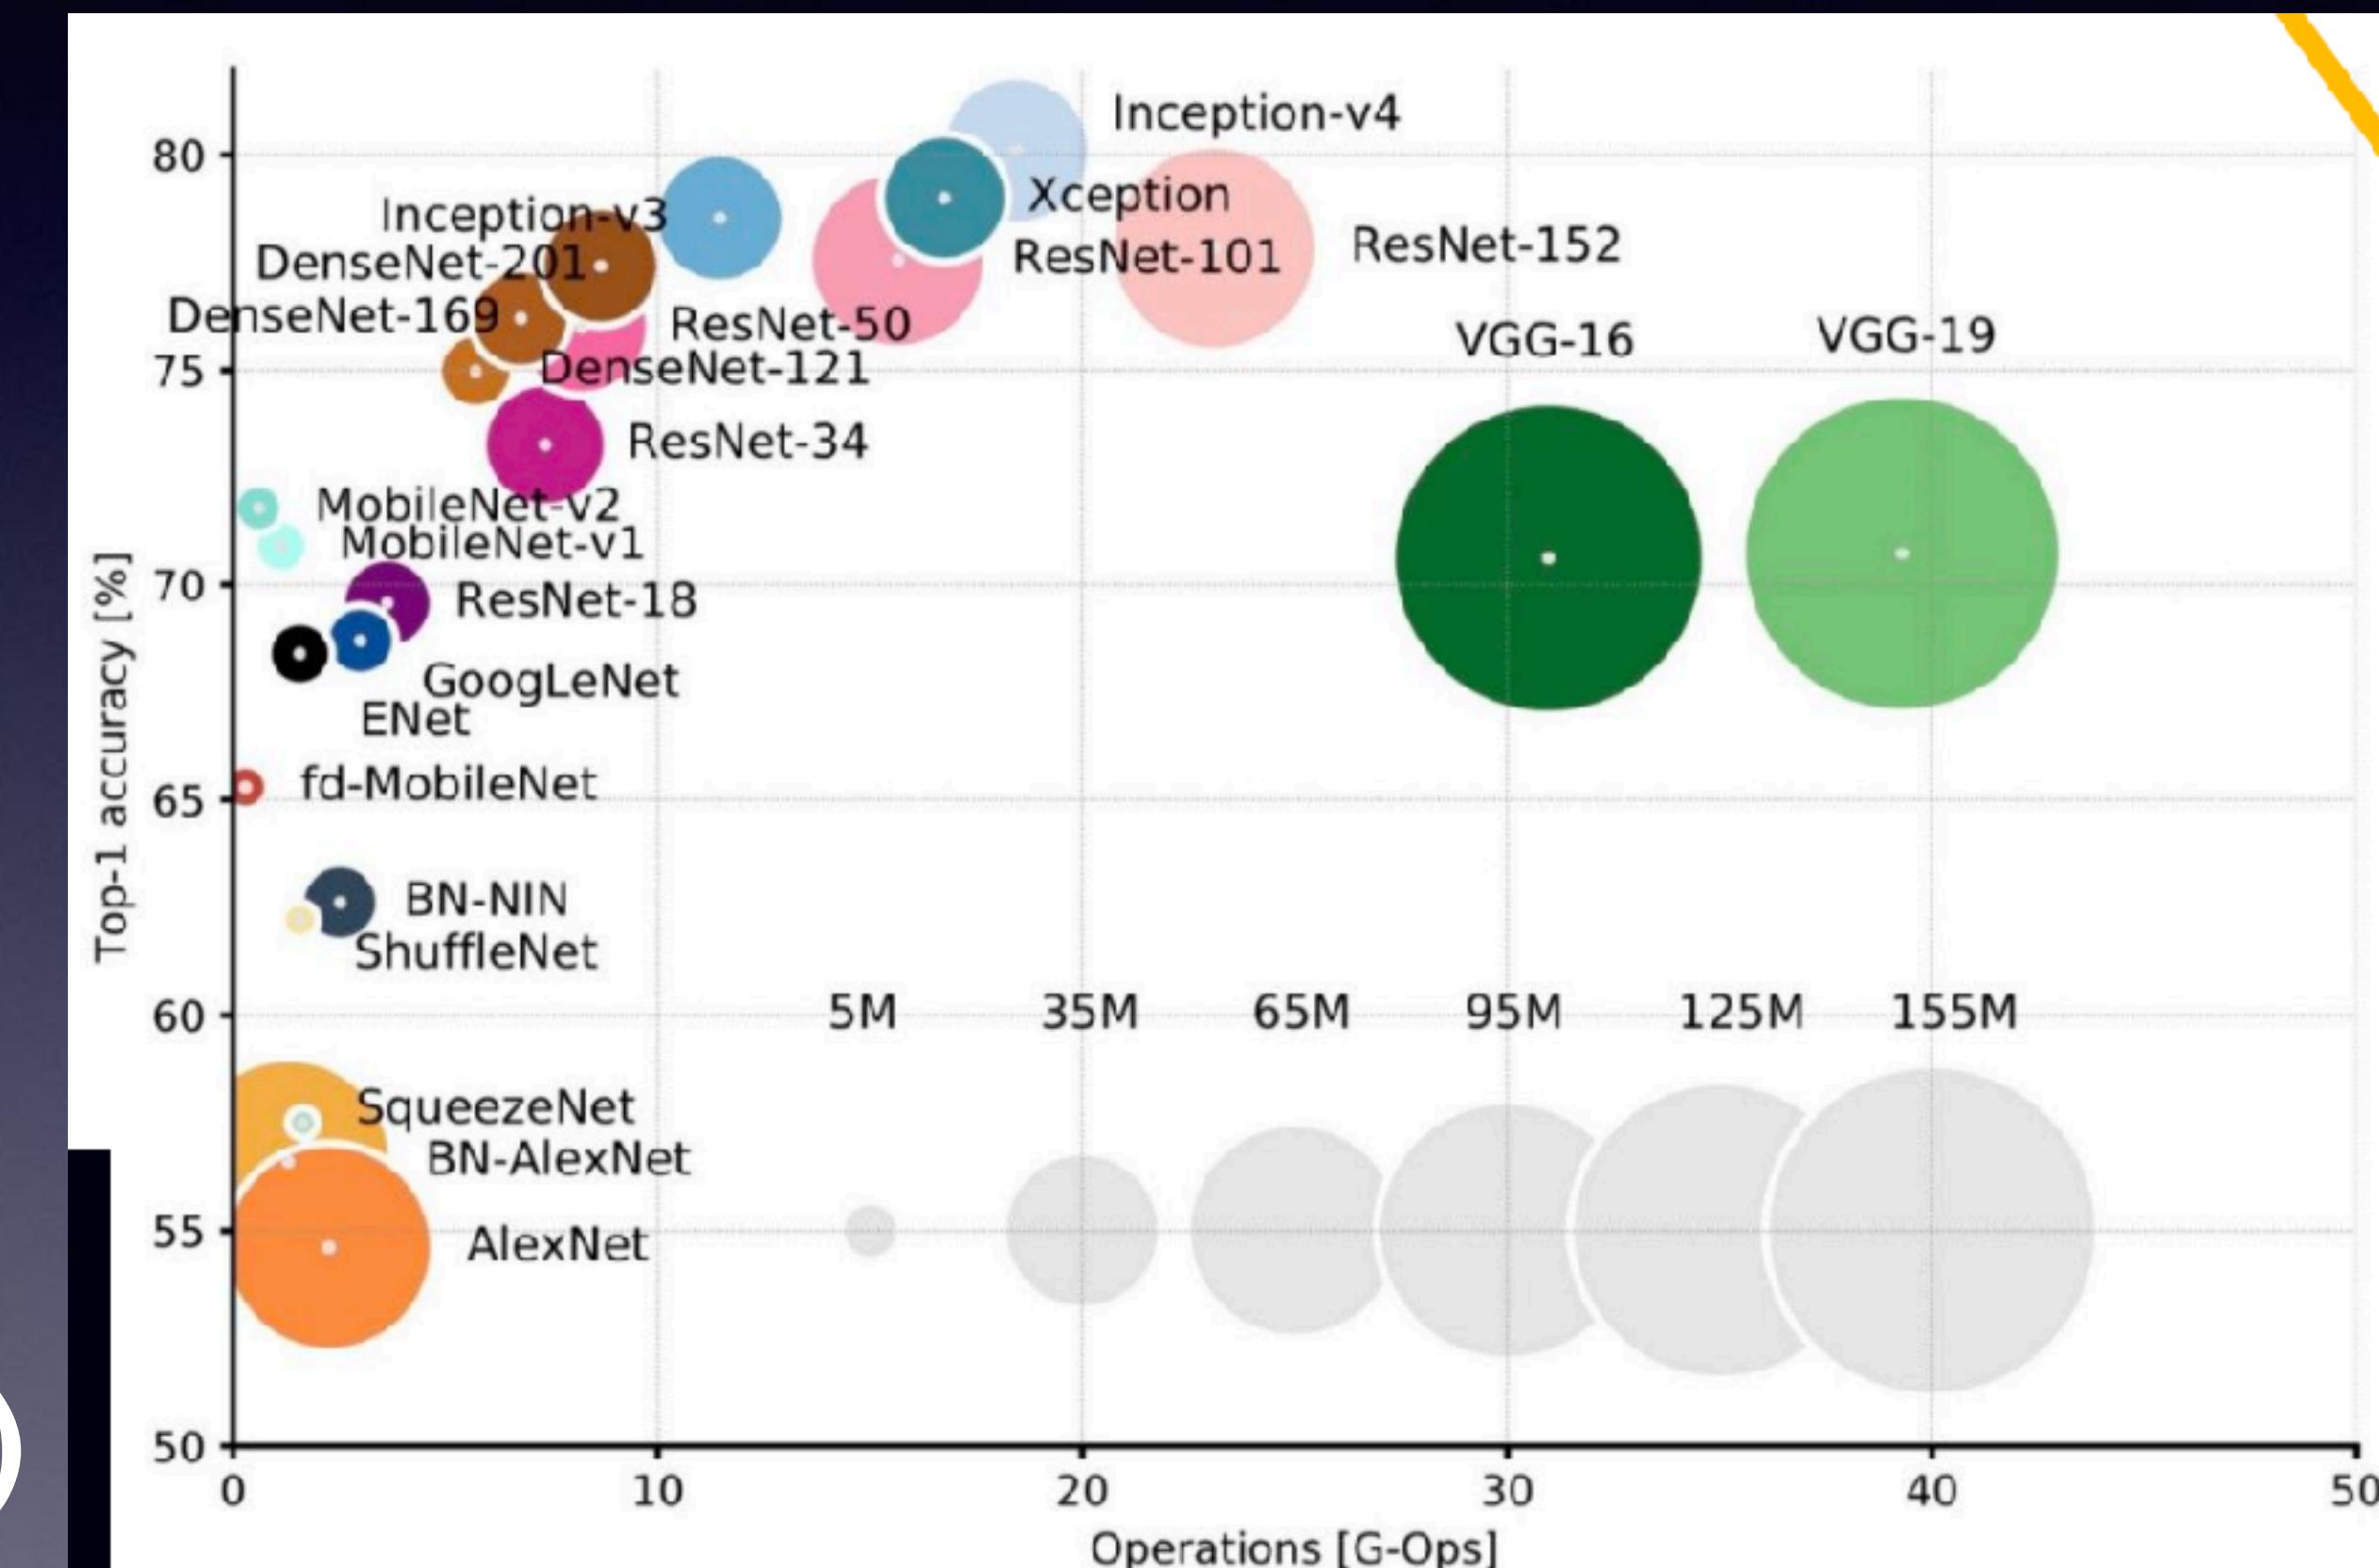
1. Rôzne veľkosti obrázkov: (710, 690), (602,339), (425,160)
2. Formát/ počet obrázkov: '.jpg': 12058, '.jpeg': 11780, '.png': 35
3. RGBA (Red, Green, Blue, Alpha) - alpha - 4 kanál priehľadnosť pixelu (0 -255) - .png
4. RGB (Red, Green, Blue) - .jpeg, .jpg

# Problém

- Vysoký počet obrázkov (23 873)
- Veľké pamäťové nároky - COLAB - reštart relácie (RAM limit)
- Použitie **ImageDataGenerator** namiesto načítania celého datasetu do pamäte
- Dynamické načítavanie obrázkov počas trénovania namiesto ich držania v pamäti

# Použité modely

- Transfer learning (TL):
  - MobileNetV2 (MN2)
  - EfficientNetB2 (ENB2)
  - ResNet50V2 (RN502)
  - Vlastná Neurónka (VN)



# Testované modely

1. Trénovanie modelu so „zmrazenými“ vrstvami TL modelu bez regularizácie- značný overfitting (accuracy vs. val\_accuracy)
2. Trénovanie modelu so „zmrazenými“ vrstvami TL modelu s použitím regularizácie - potlačenie overfittingu (accuracy vs. val\_accuracy)
3. Vlastná neurónka

# 1. Nastavenie modelov bez regularizácie

1. Použitie generátoru dát - ImageDataGenerator pre trénovacie i validačné dáta (split 80/20 - trénovacie / testovacie)
2. Použitie funkcie preprocess\_input pre jednotlivé modely
3. MN2 (224, 224, 3), ENB2 (260, 260, 3), RN502 (224, 224, 3)
4. Batch = 16, Epochy = 5,
5. **Klasifikačná vrstva:** Optimizer = Adam, Stratová (loss) funkcia = categorical\_crossentropy, aktivačná funkcia = ReLU, Dense vrstva s 512 neurónmi
6. **Výstupná vrstva:** aktivačná funkcia = softmax
7. Optimizer = Adam, EarlyStopping, ModelCheckpoint

## 2. Nastavenie modelov s regularizáciou

1. Rovnaké nastavenie ako modely bez regularizácie
2. Pridané parametre:
  - A. Augmentácia trénovacích dát (náhodný posun (V/H)/ deformácia)
  - B. BatchNormalization, Dropout, L2 regularizácia
  - C. Optimizer = Adam, callbacky = earlystopping, modelcheckpoint

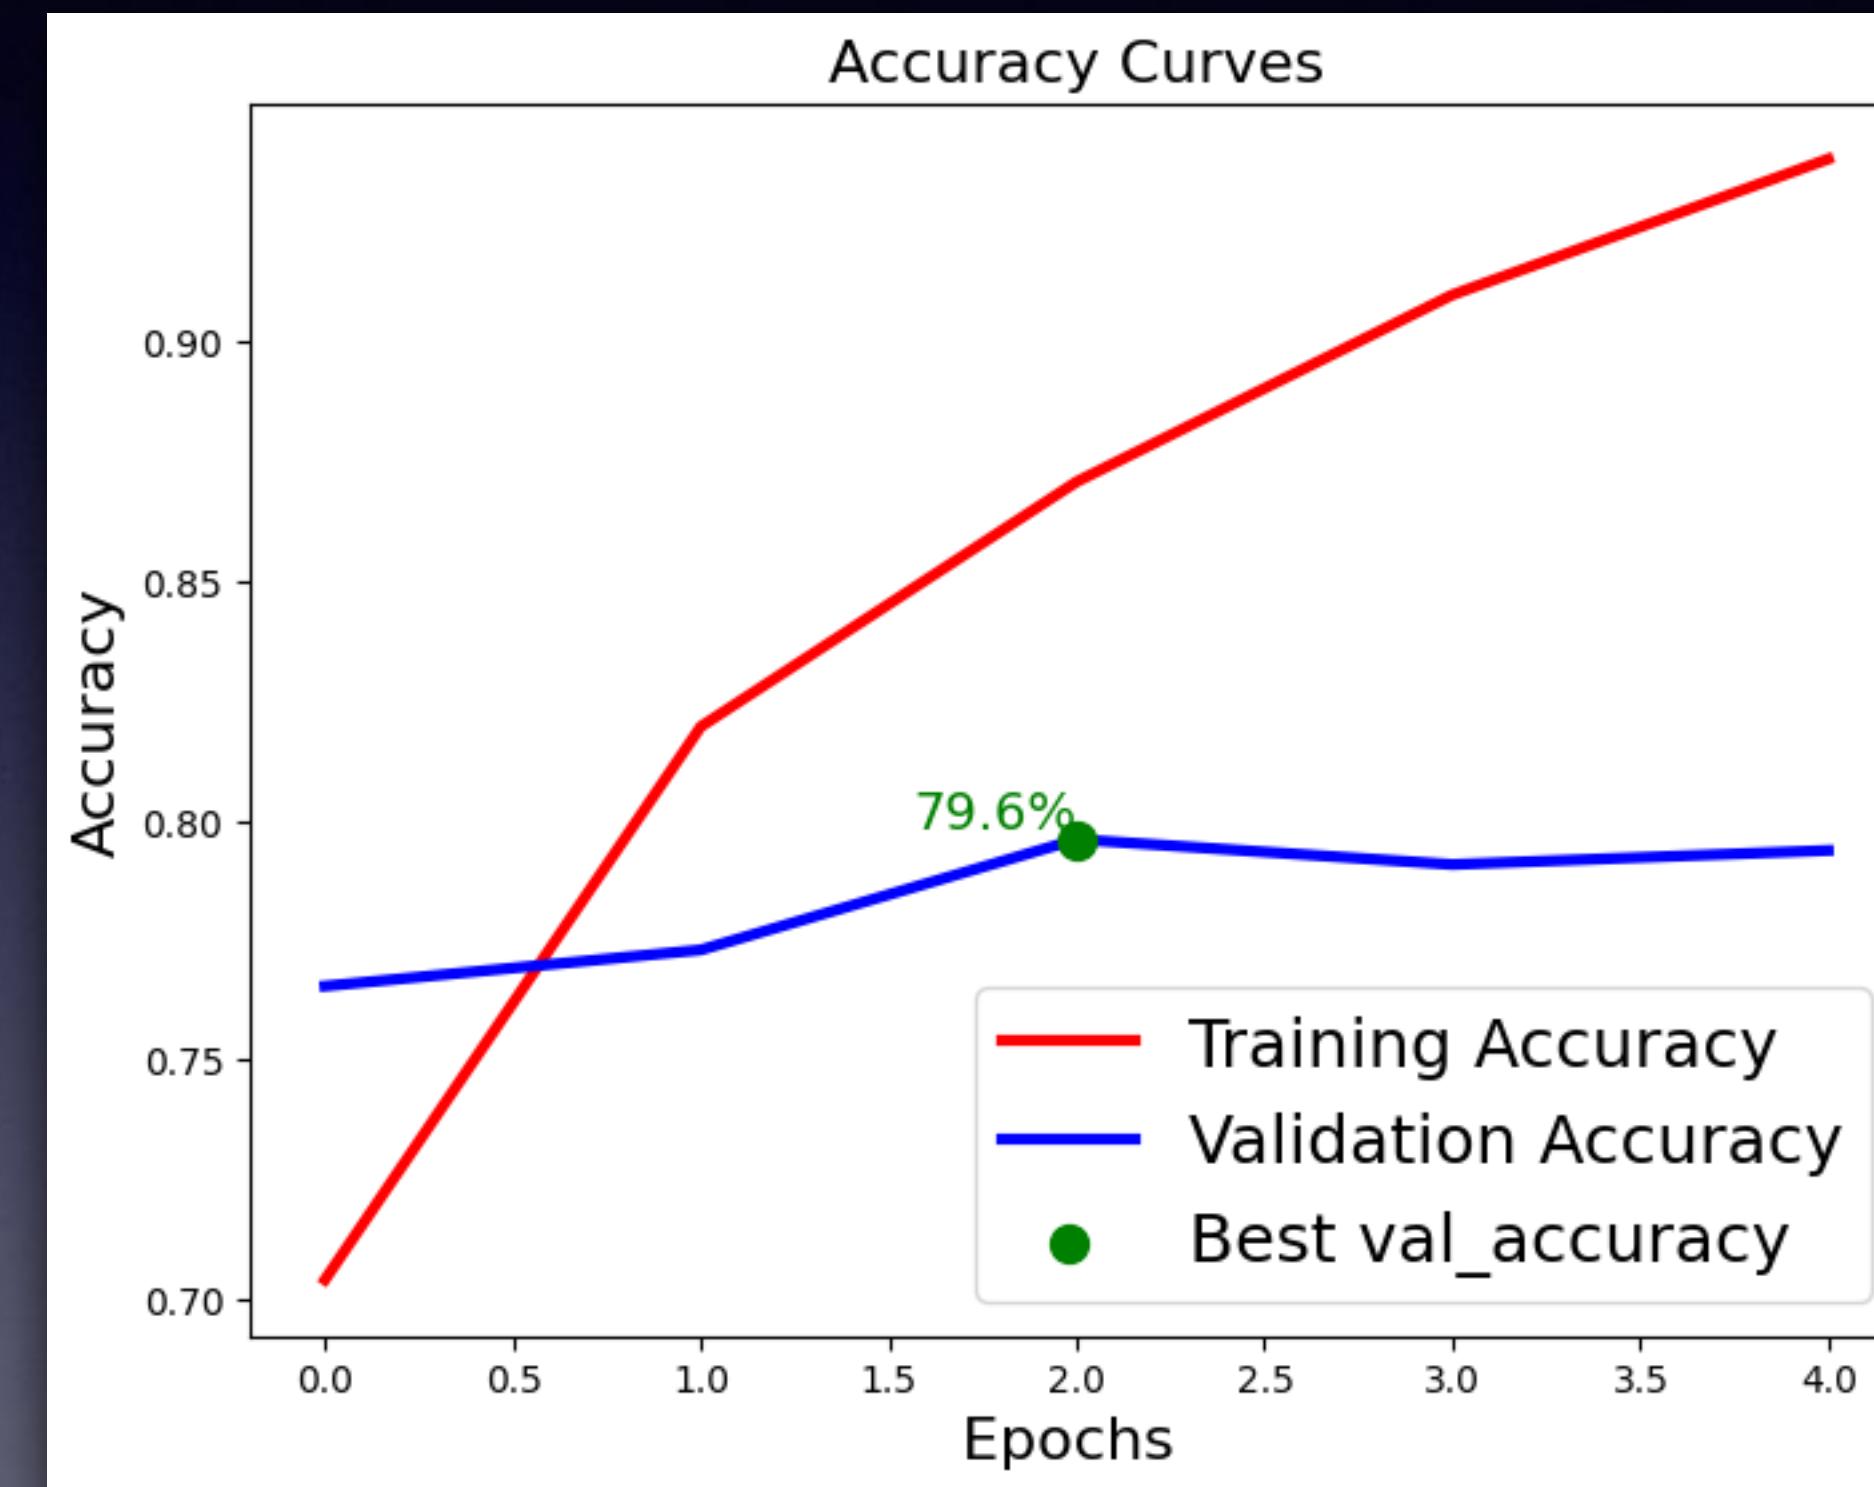
# 3. Vlastná neurónka

1. Architektúra
  - A. 5 konvolučných blokov ( $64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 512$  filtrov)
  - B. Každý blok obsahuje:  $2 \times \text{Conv2D} \rightarrow \text{ReLU} \rightarrow \text{BatchNorm} \rightarrow \text{MaxPooling}$
  - C. 3 plne prepojené vrstvy ( $512 \rightarrow 256 \rightarrow \text{počet\_tried}$ ) s Dropout pre redukciu pretrénovania
  - D. Celkom 45 vrstiev (10 konvolučných, 35 pomocných a klasifikačných)

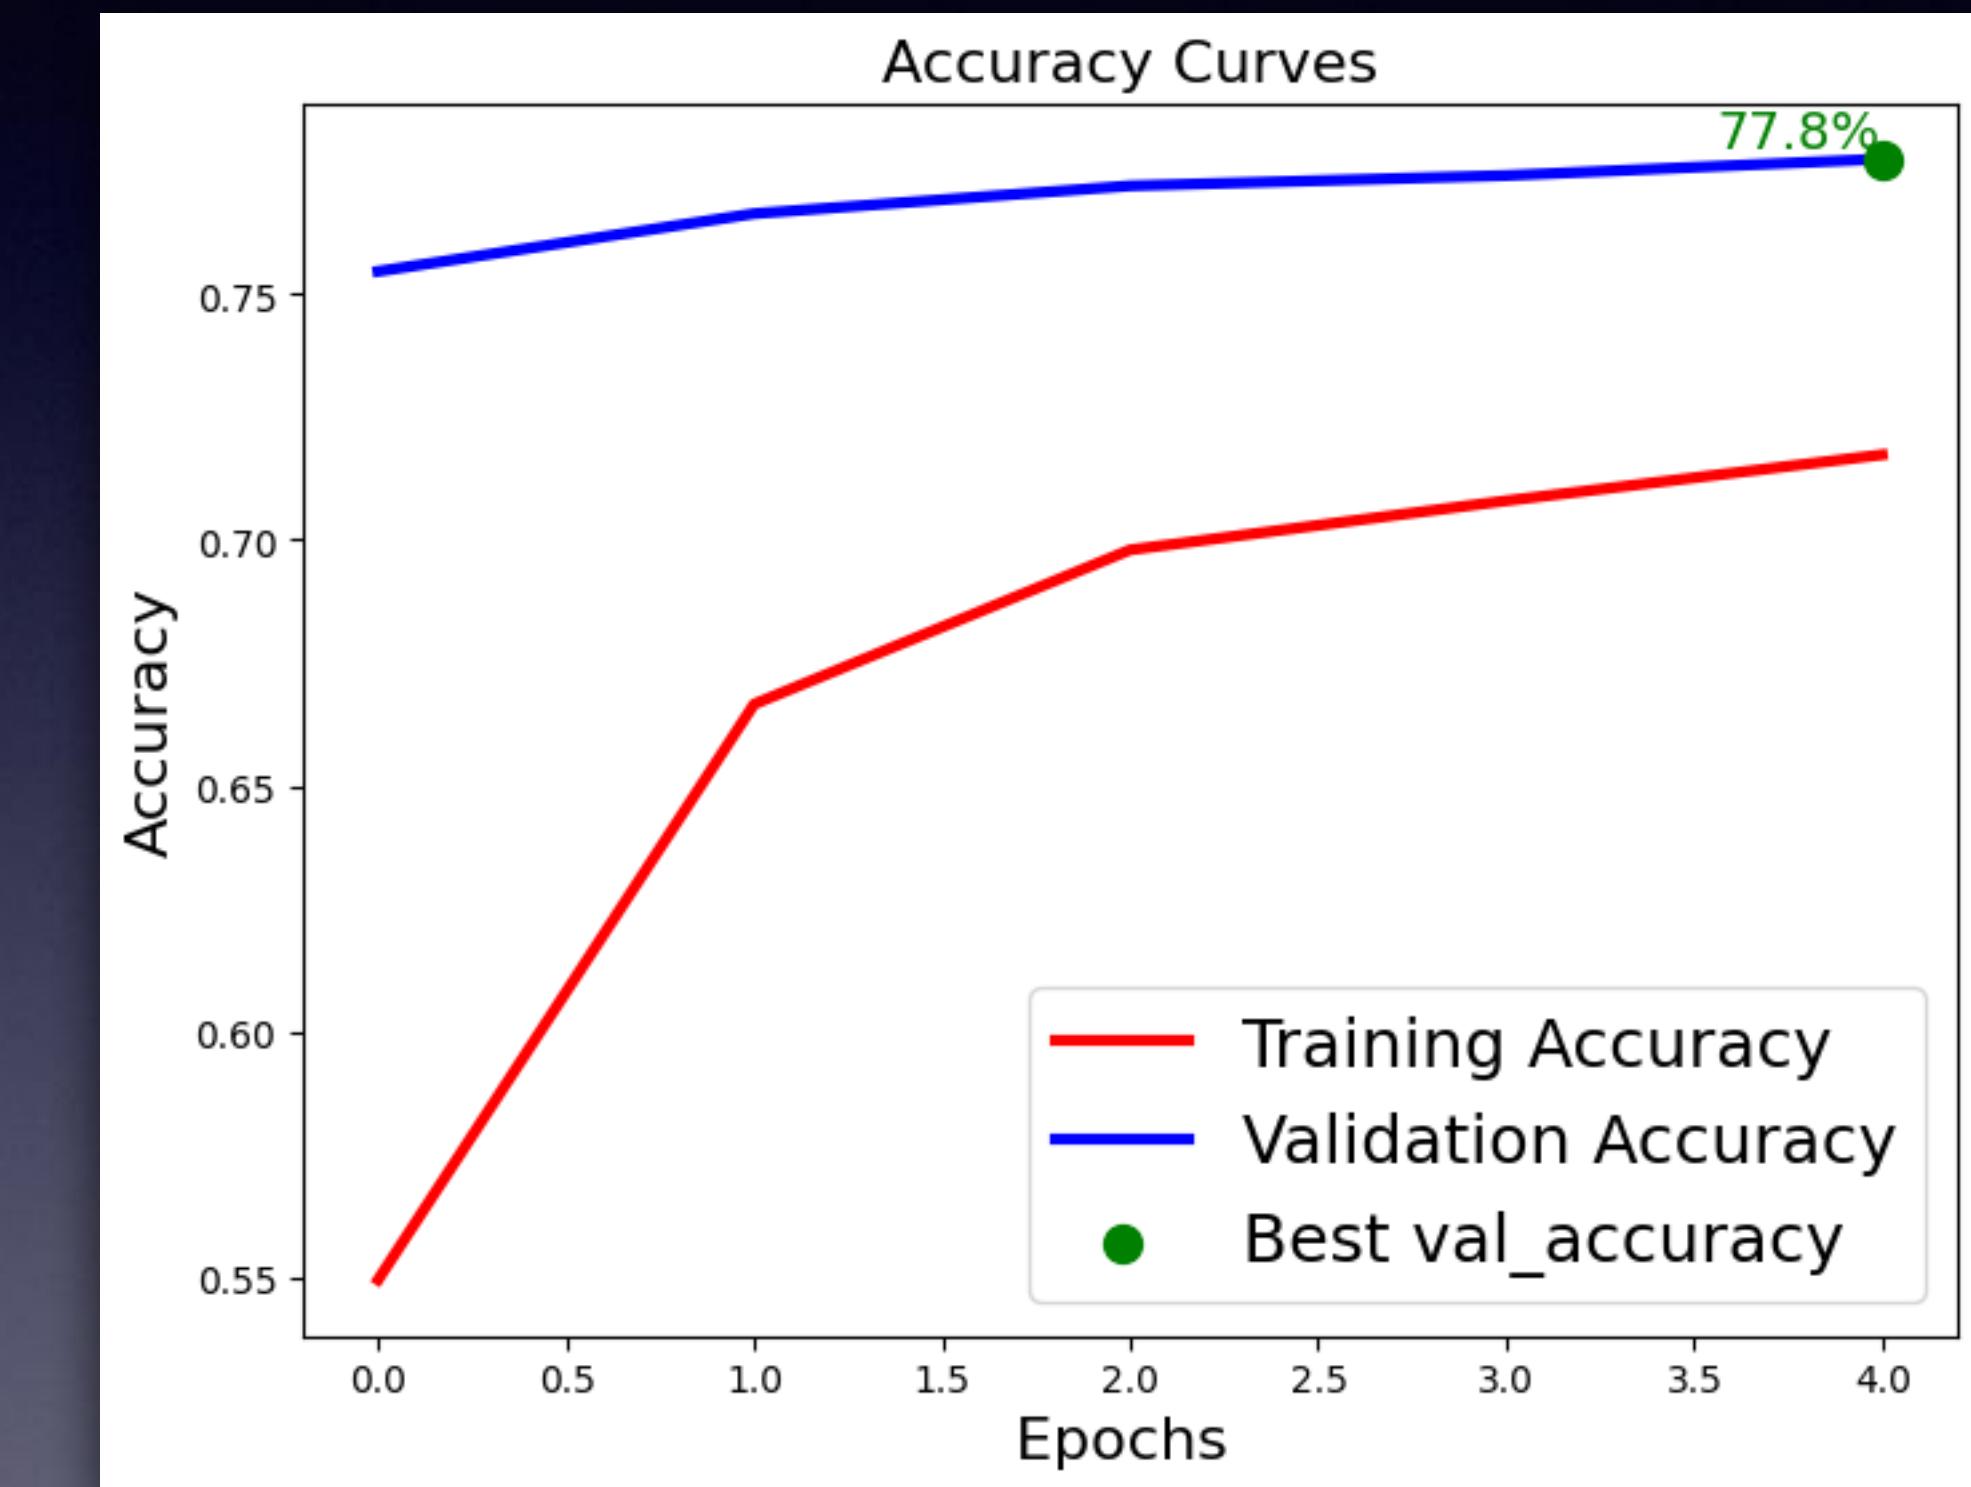
# 3. Vlastná neurónka

2. Trénovanie
  - A. Augmentácia dát (rotácia, posun, priblíženie, preklopenie)
  - B. Optimalizátor: Adam ( $\text{lr}=0.0003$ )
  - C. L2 regularizácia (0.0001) na všetkých váhach
  - D. Callbacks: Early Stopping, ModelCheckpoint, ReduceLROnPlateau
  - E. Vstupný rozmer:  $224 \times 224 \times 3$ ,  $\text{batch\_size}=16$

# MNV2

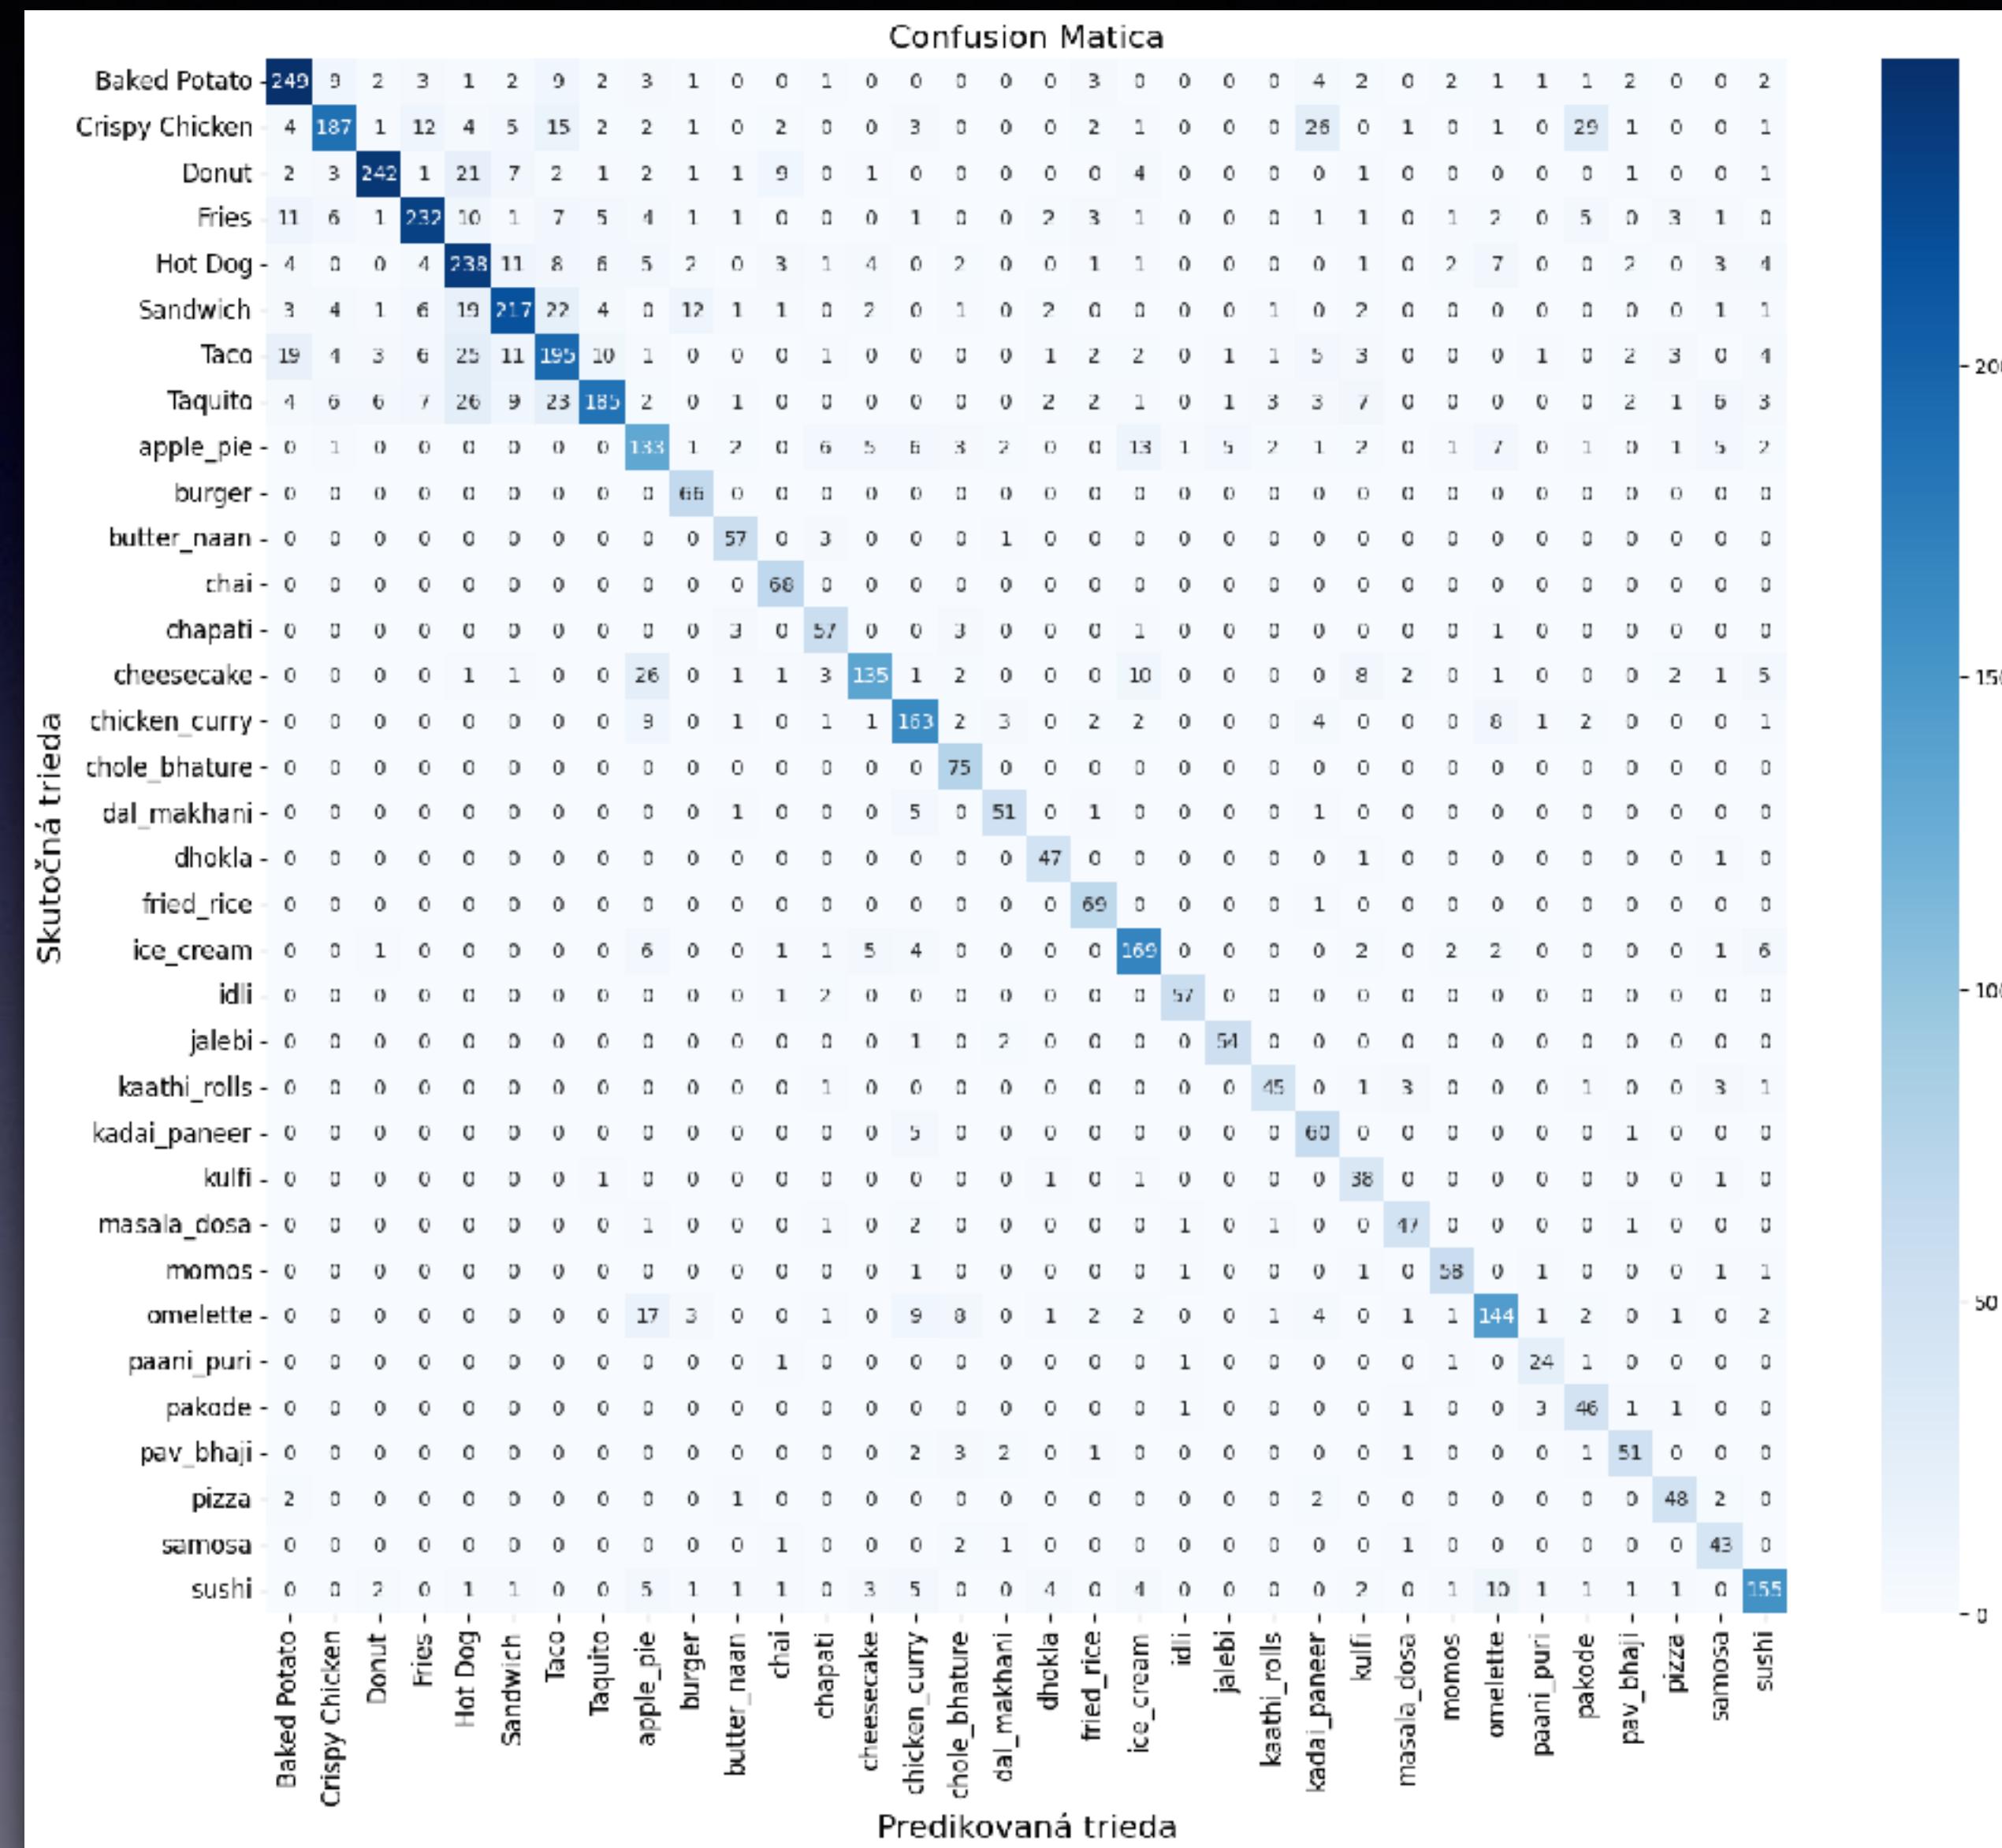


Bez regularizácie



S regularizáciou

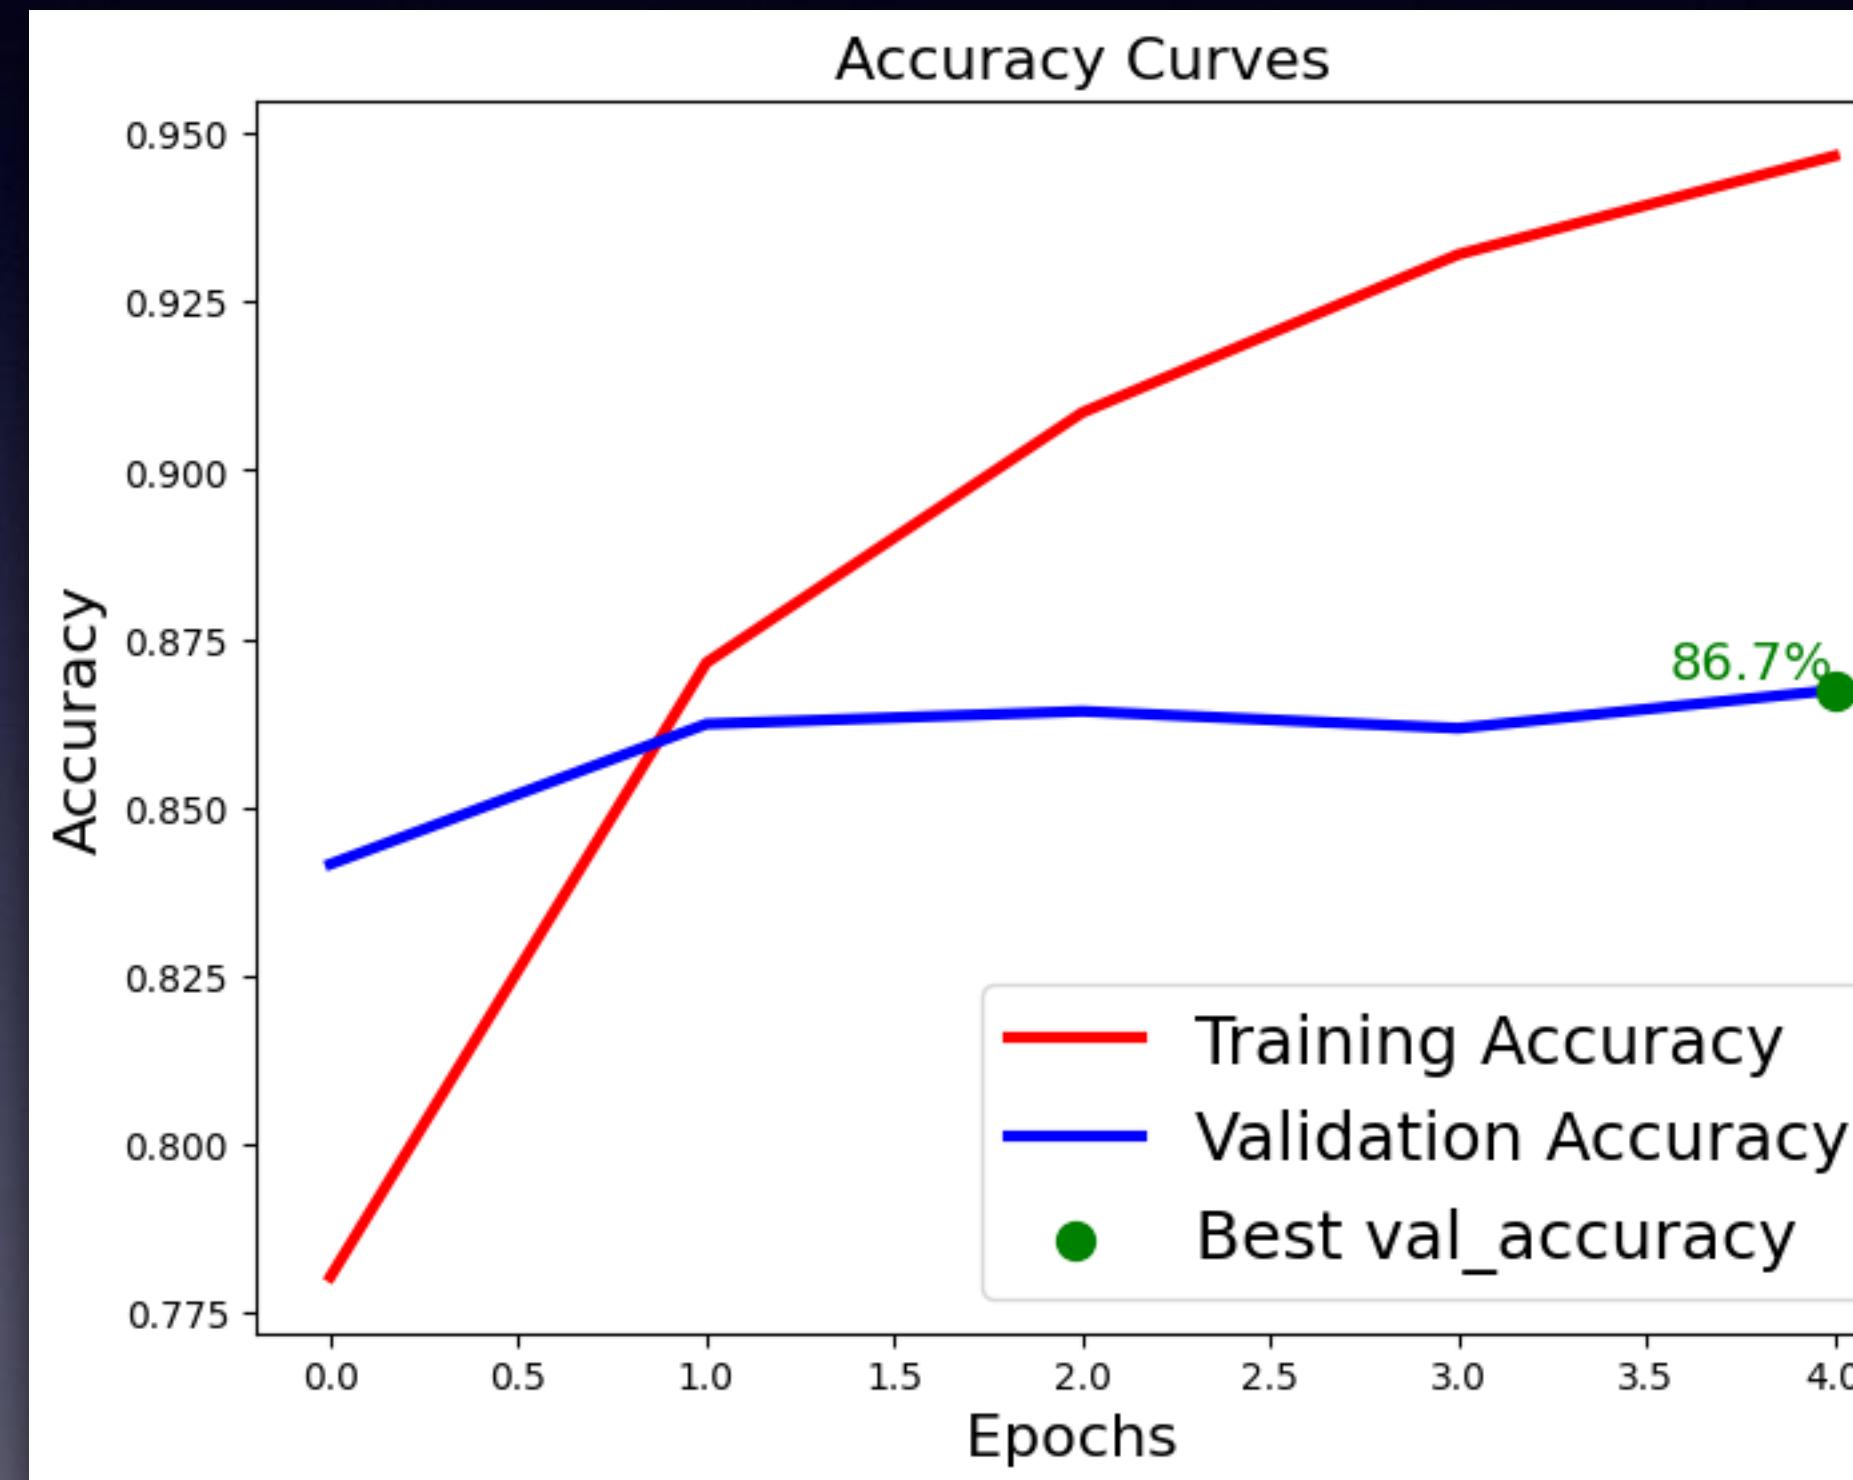
# MNV2 s regularizáciou



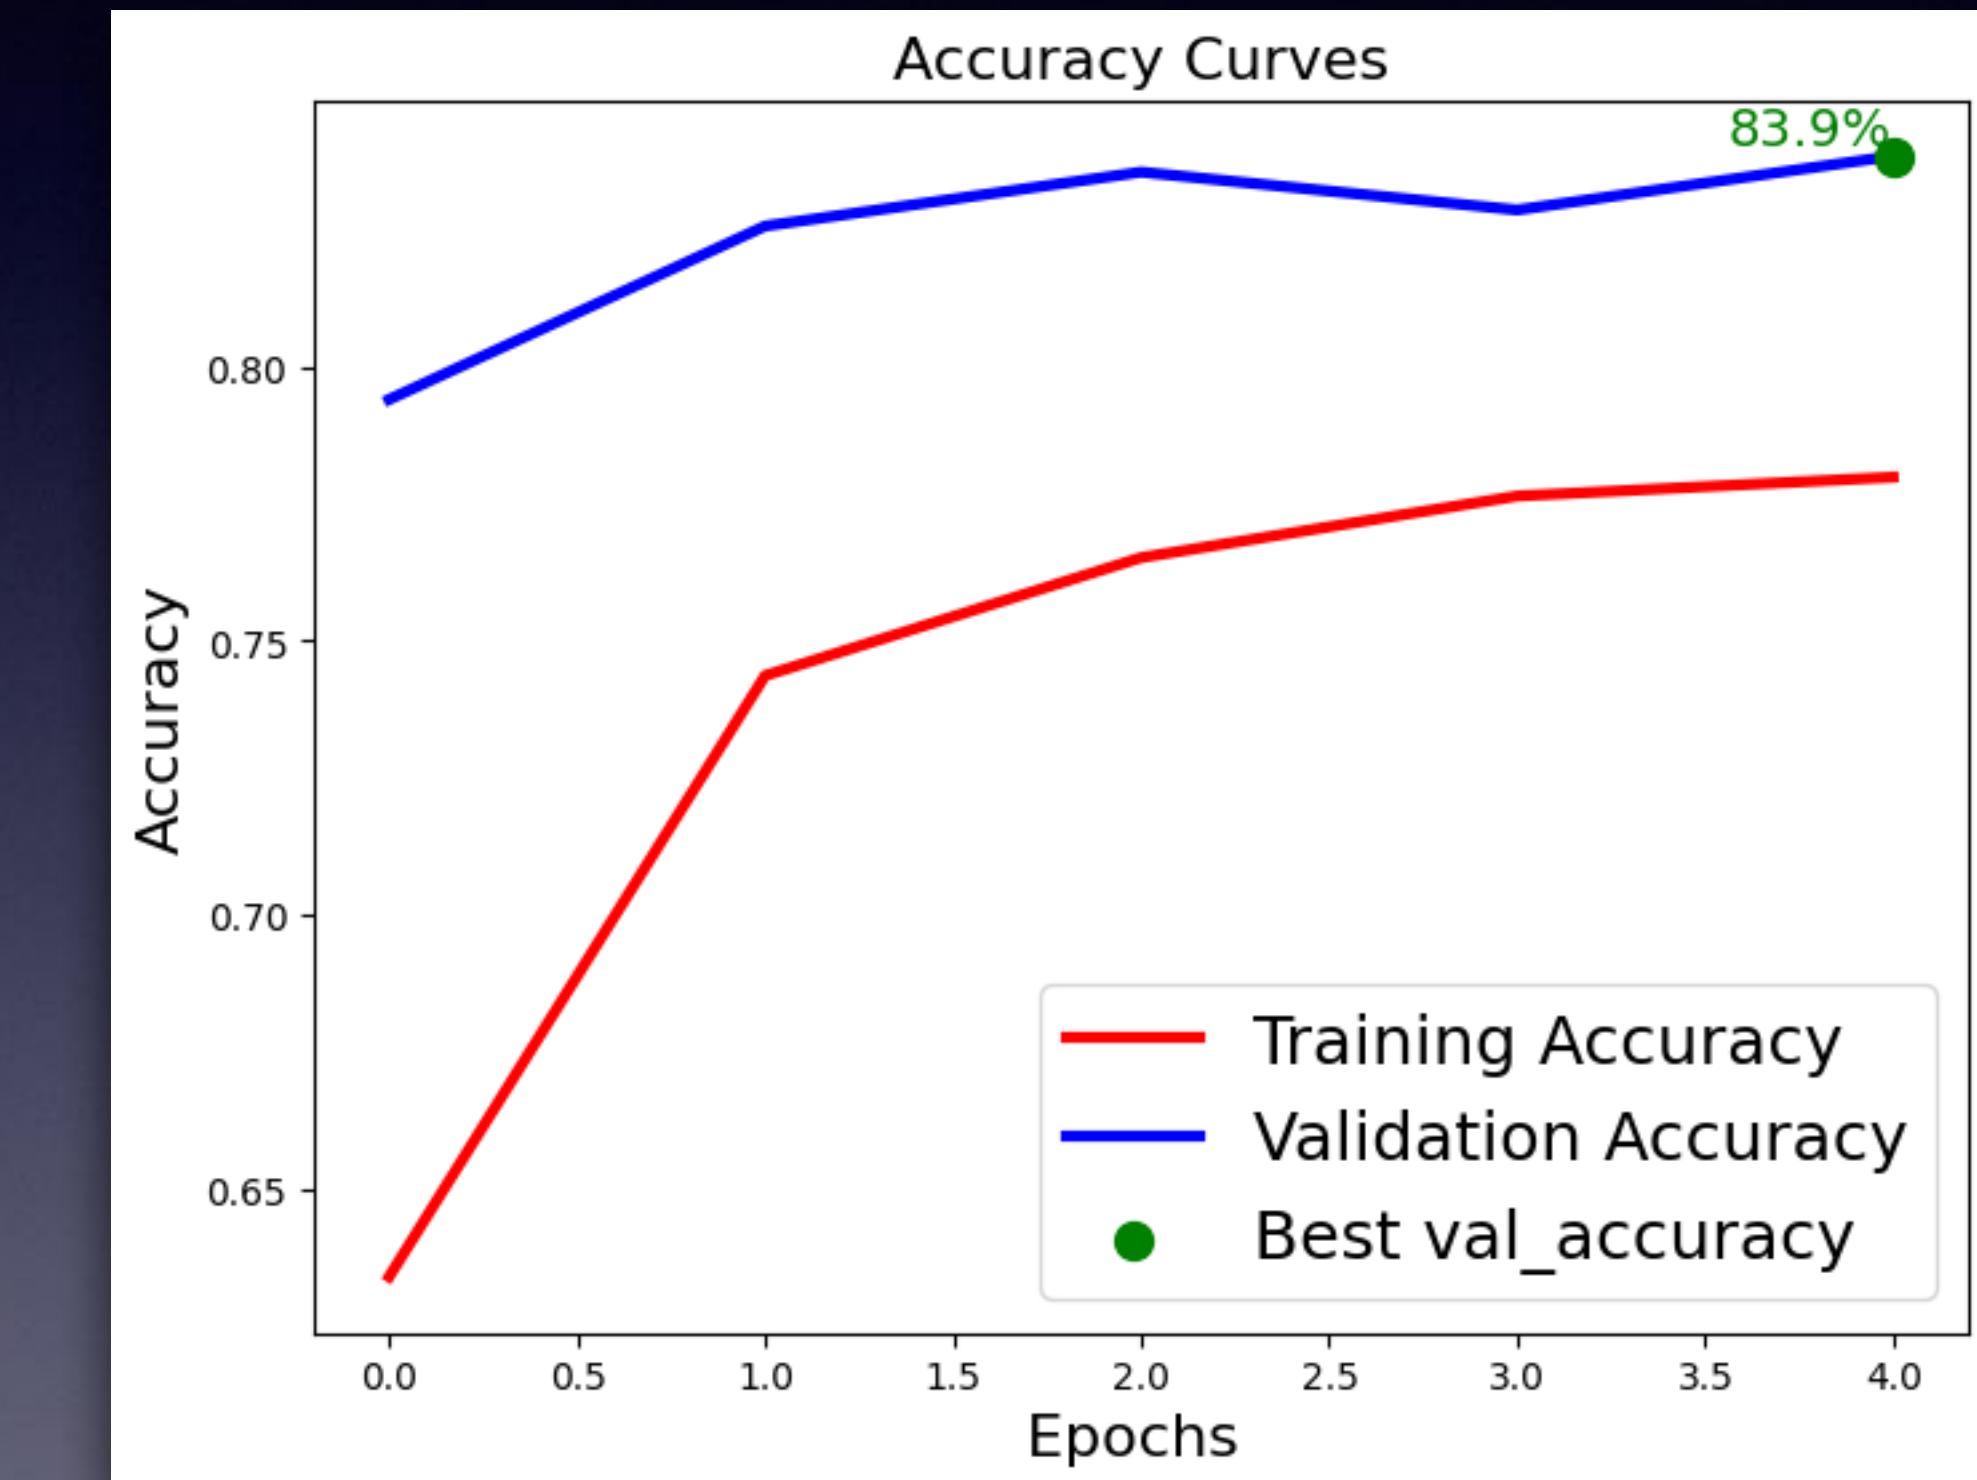
# MNV2 s regularizáciou



# ENB2

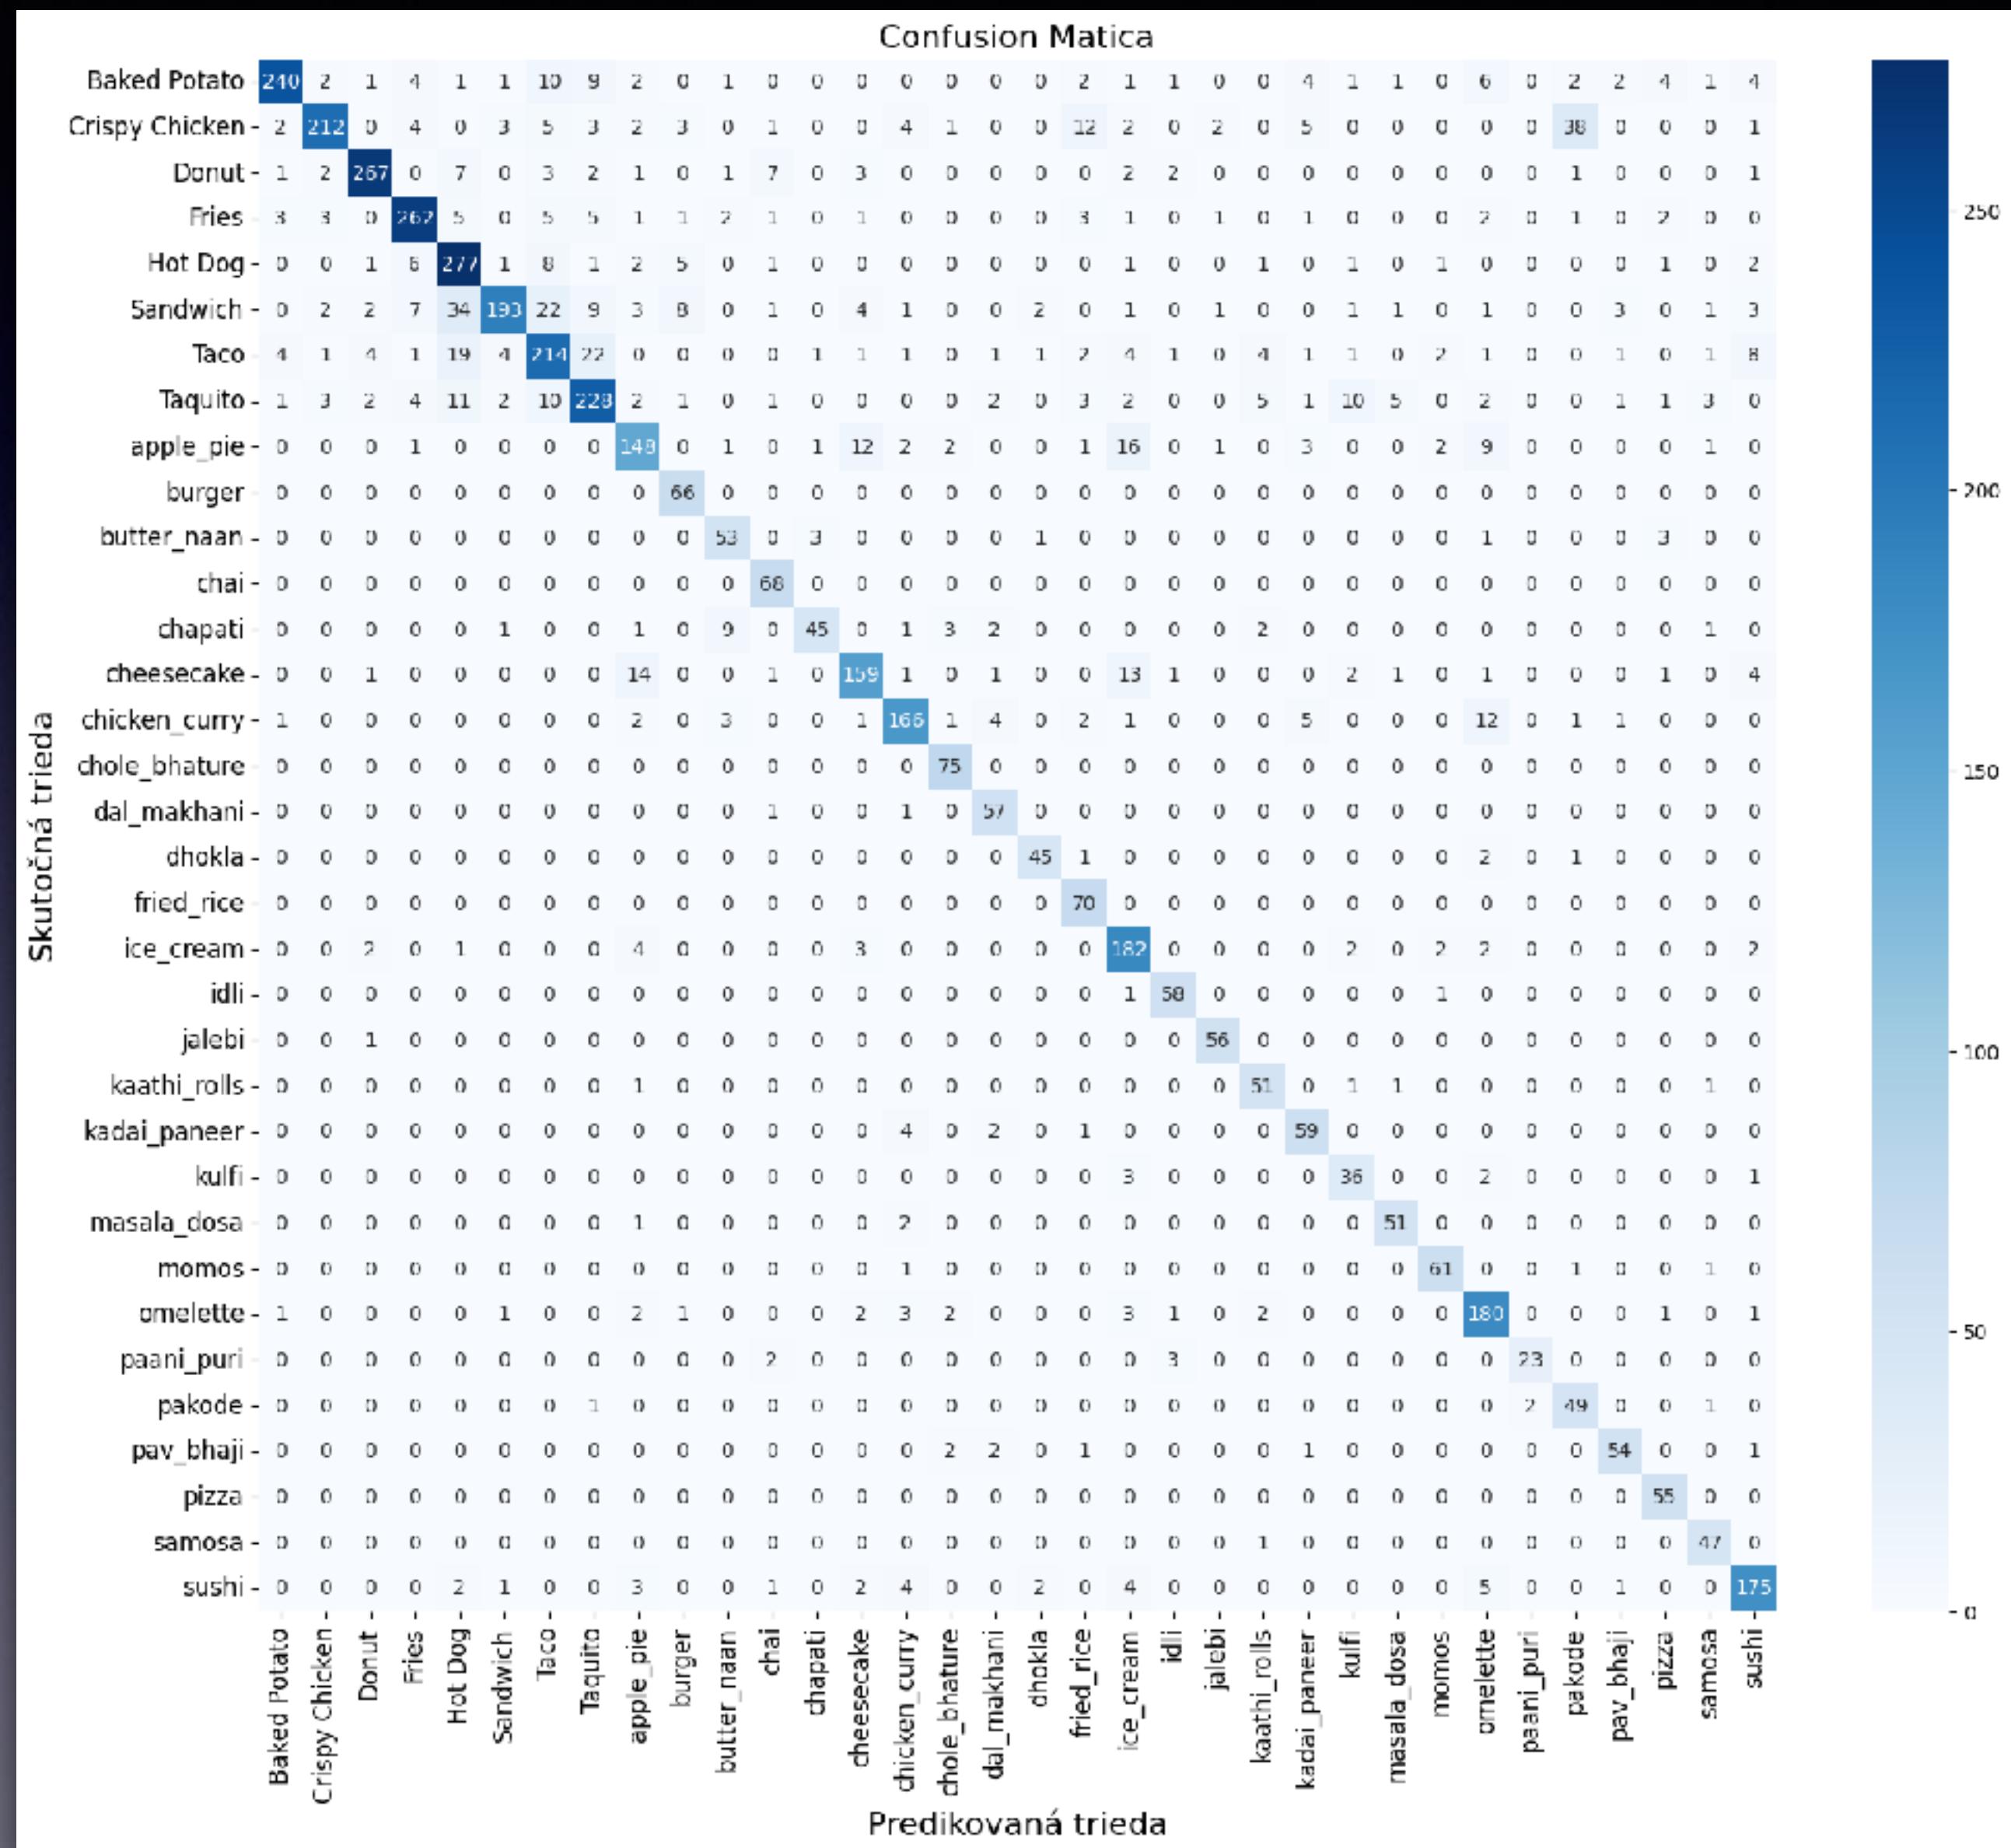


Bez regularizácie



S regularizáciou

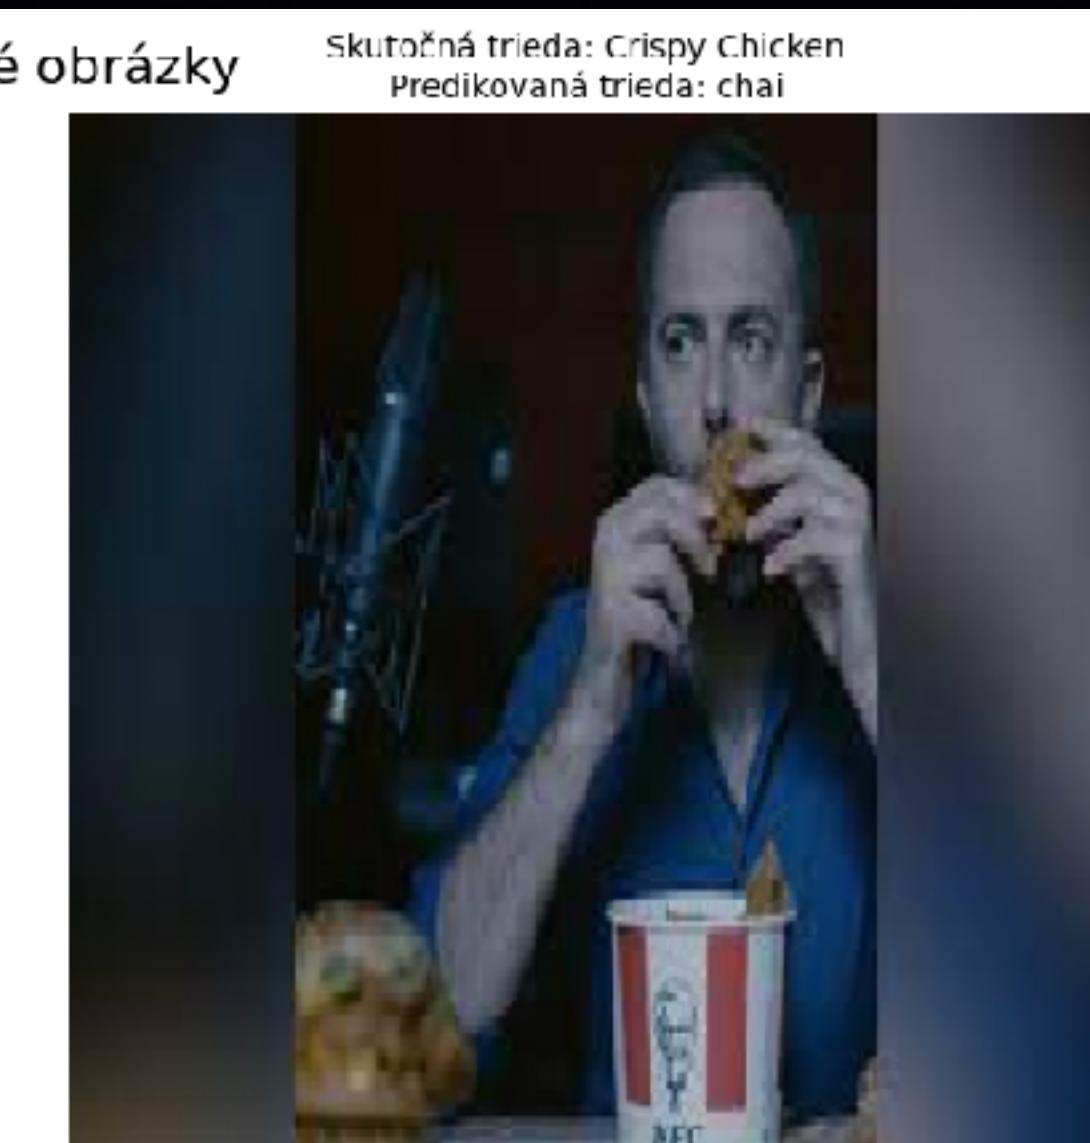
# ENB2 S regularizáciou



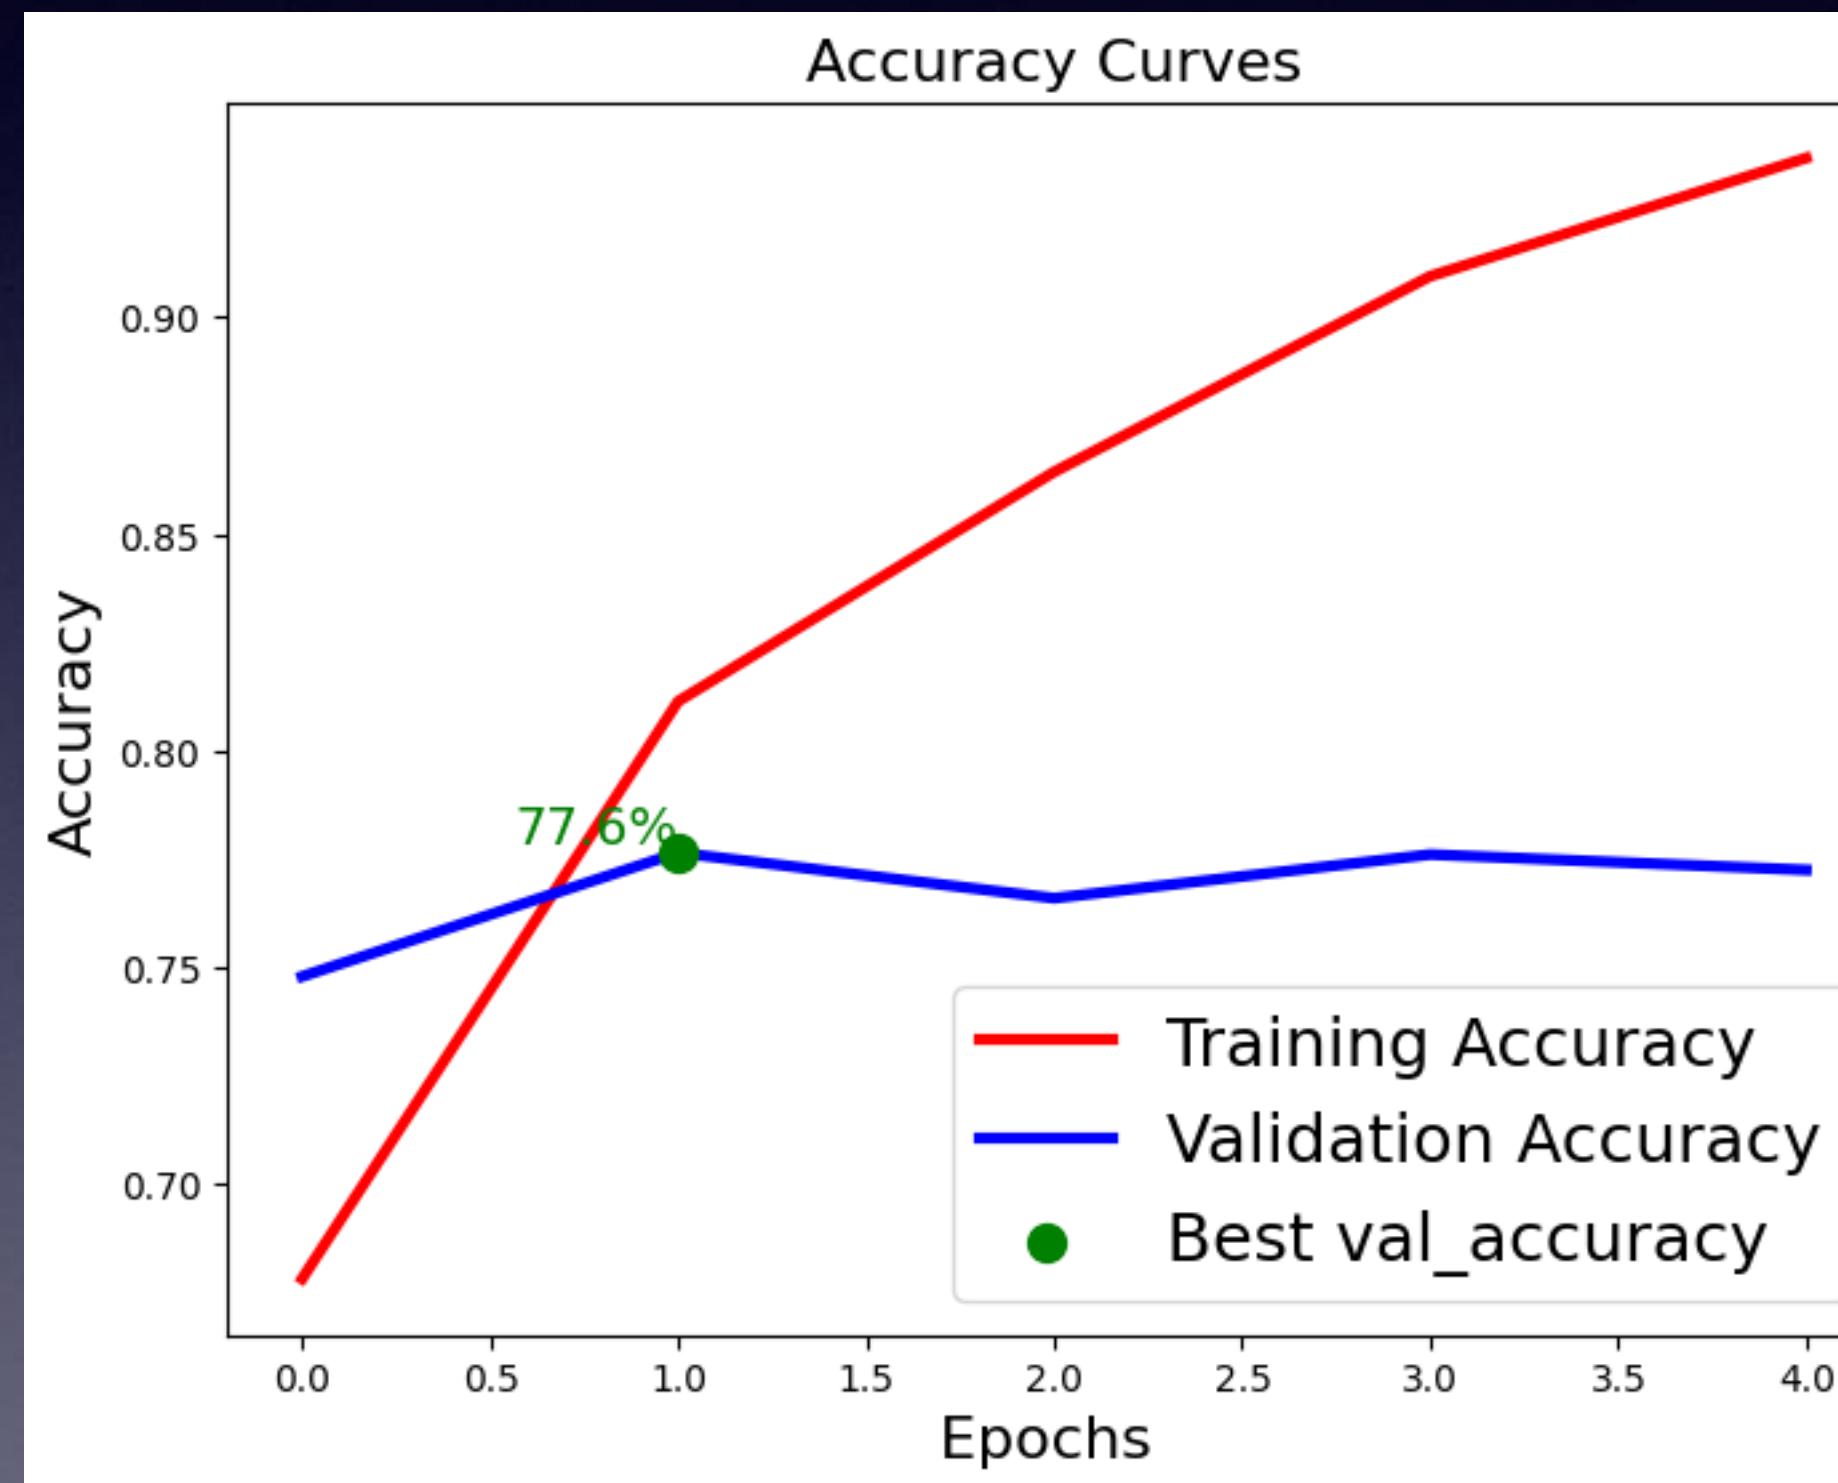
# ENB2 s regularizáciou



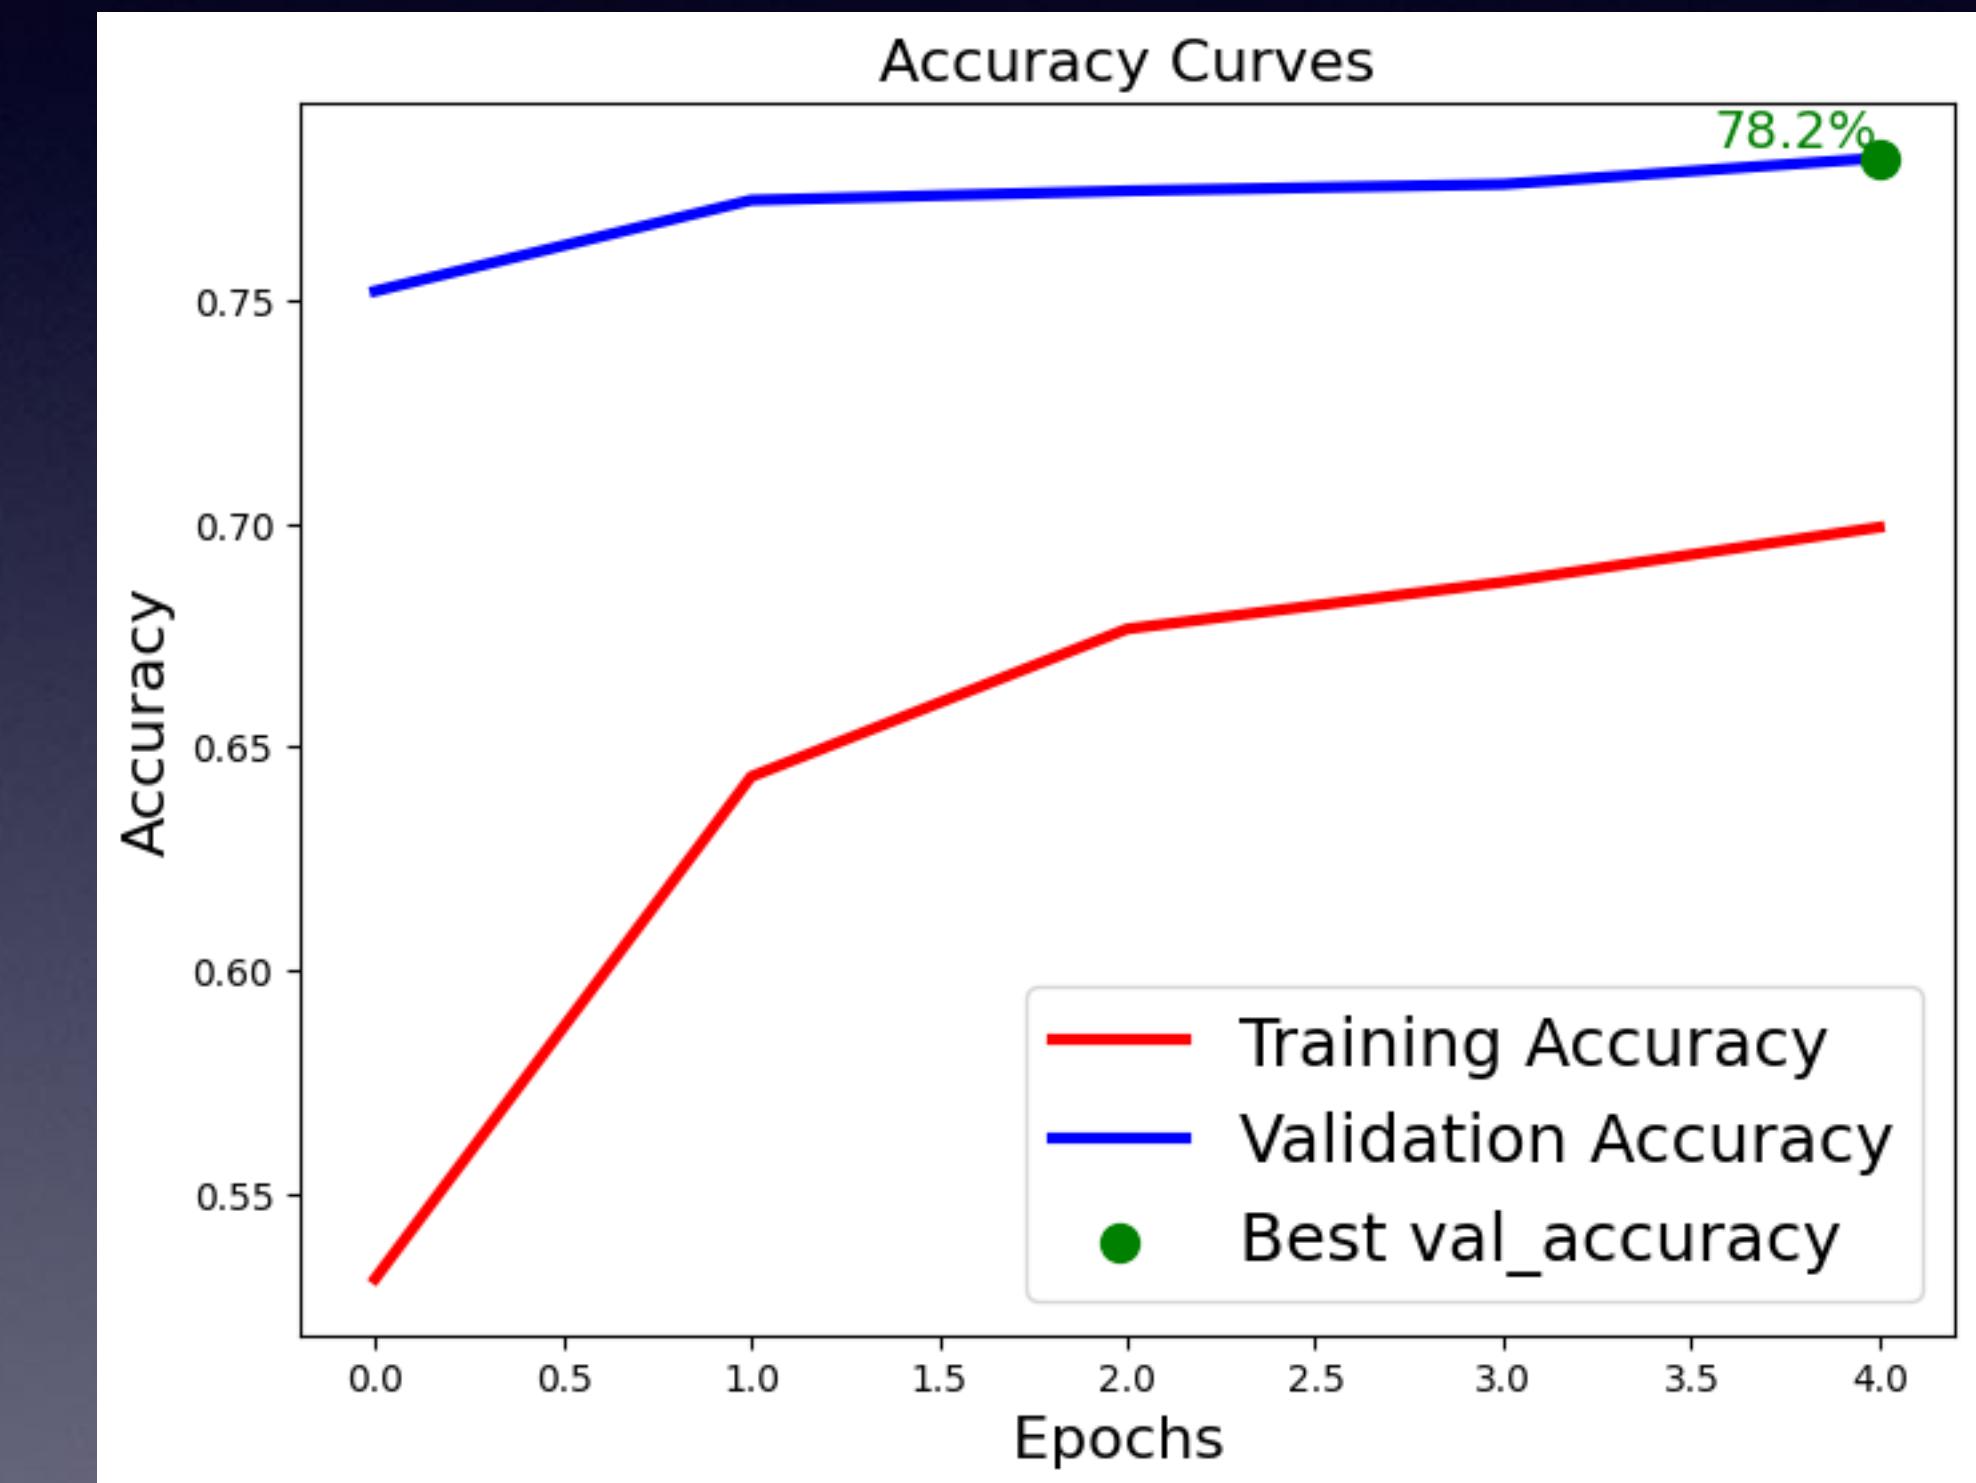
Nesprávne predikované obrázky



# RN502

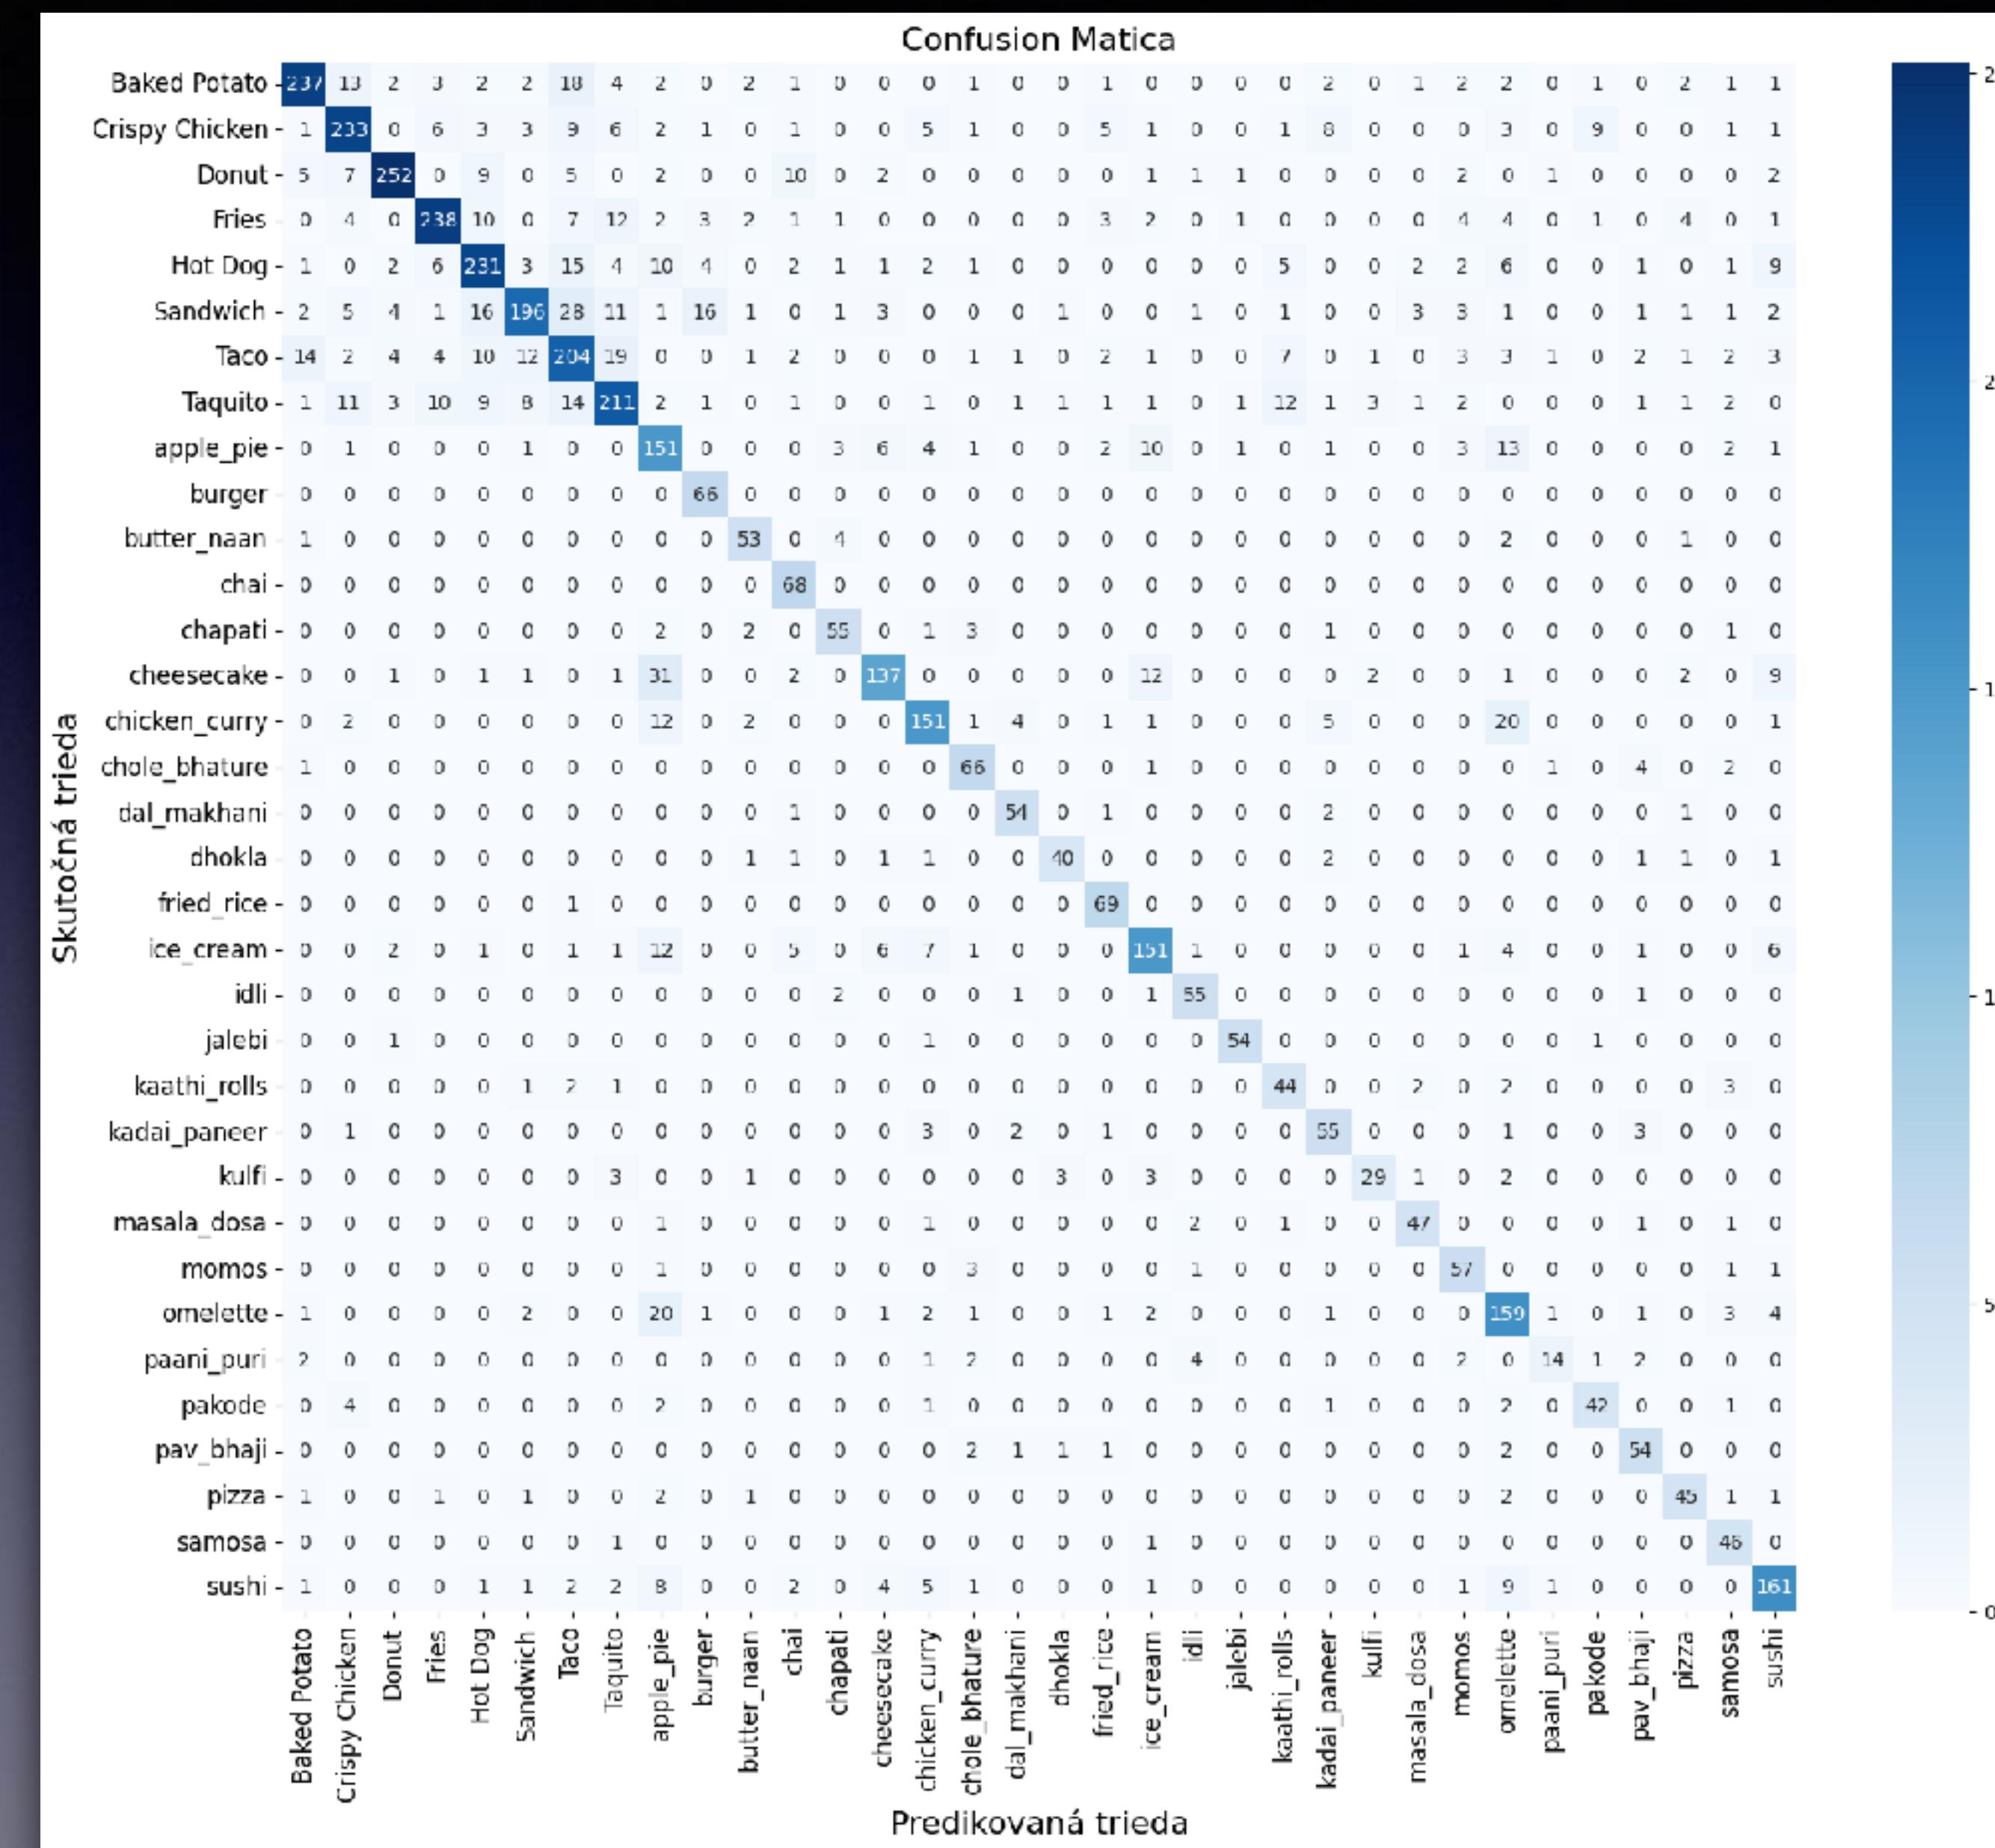


Bez regularizácie

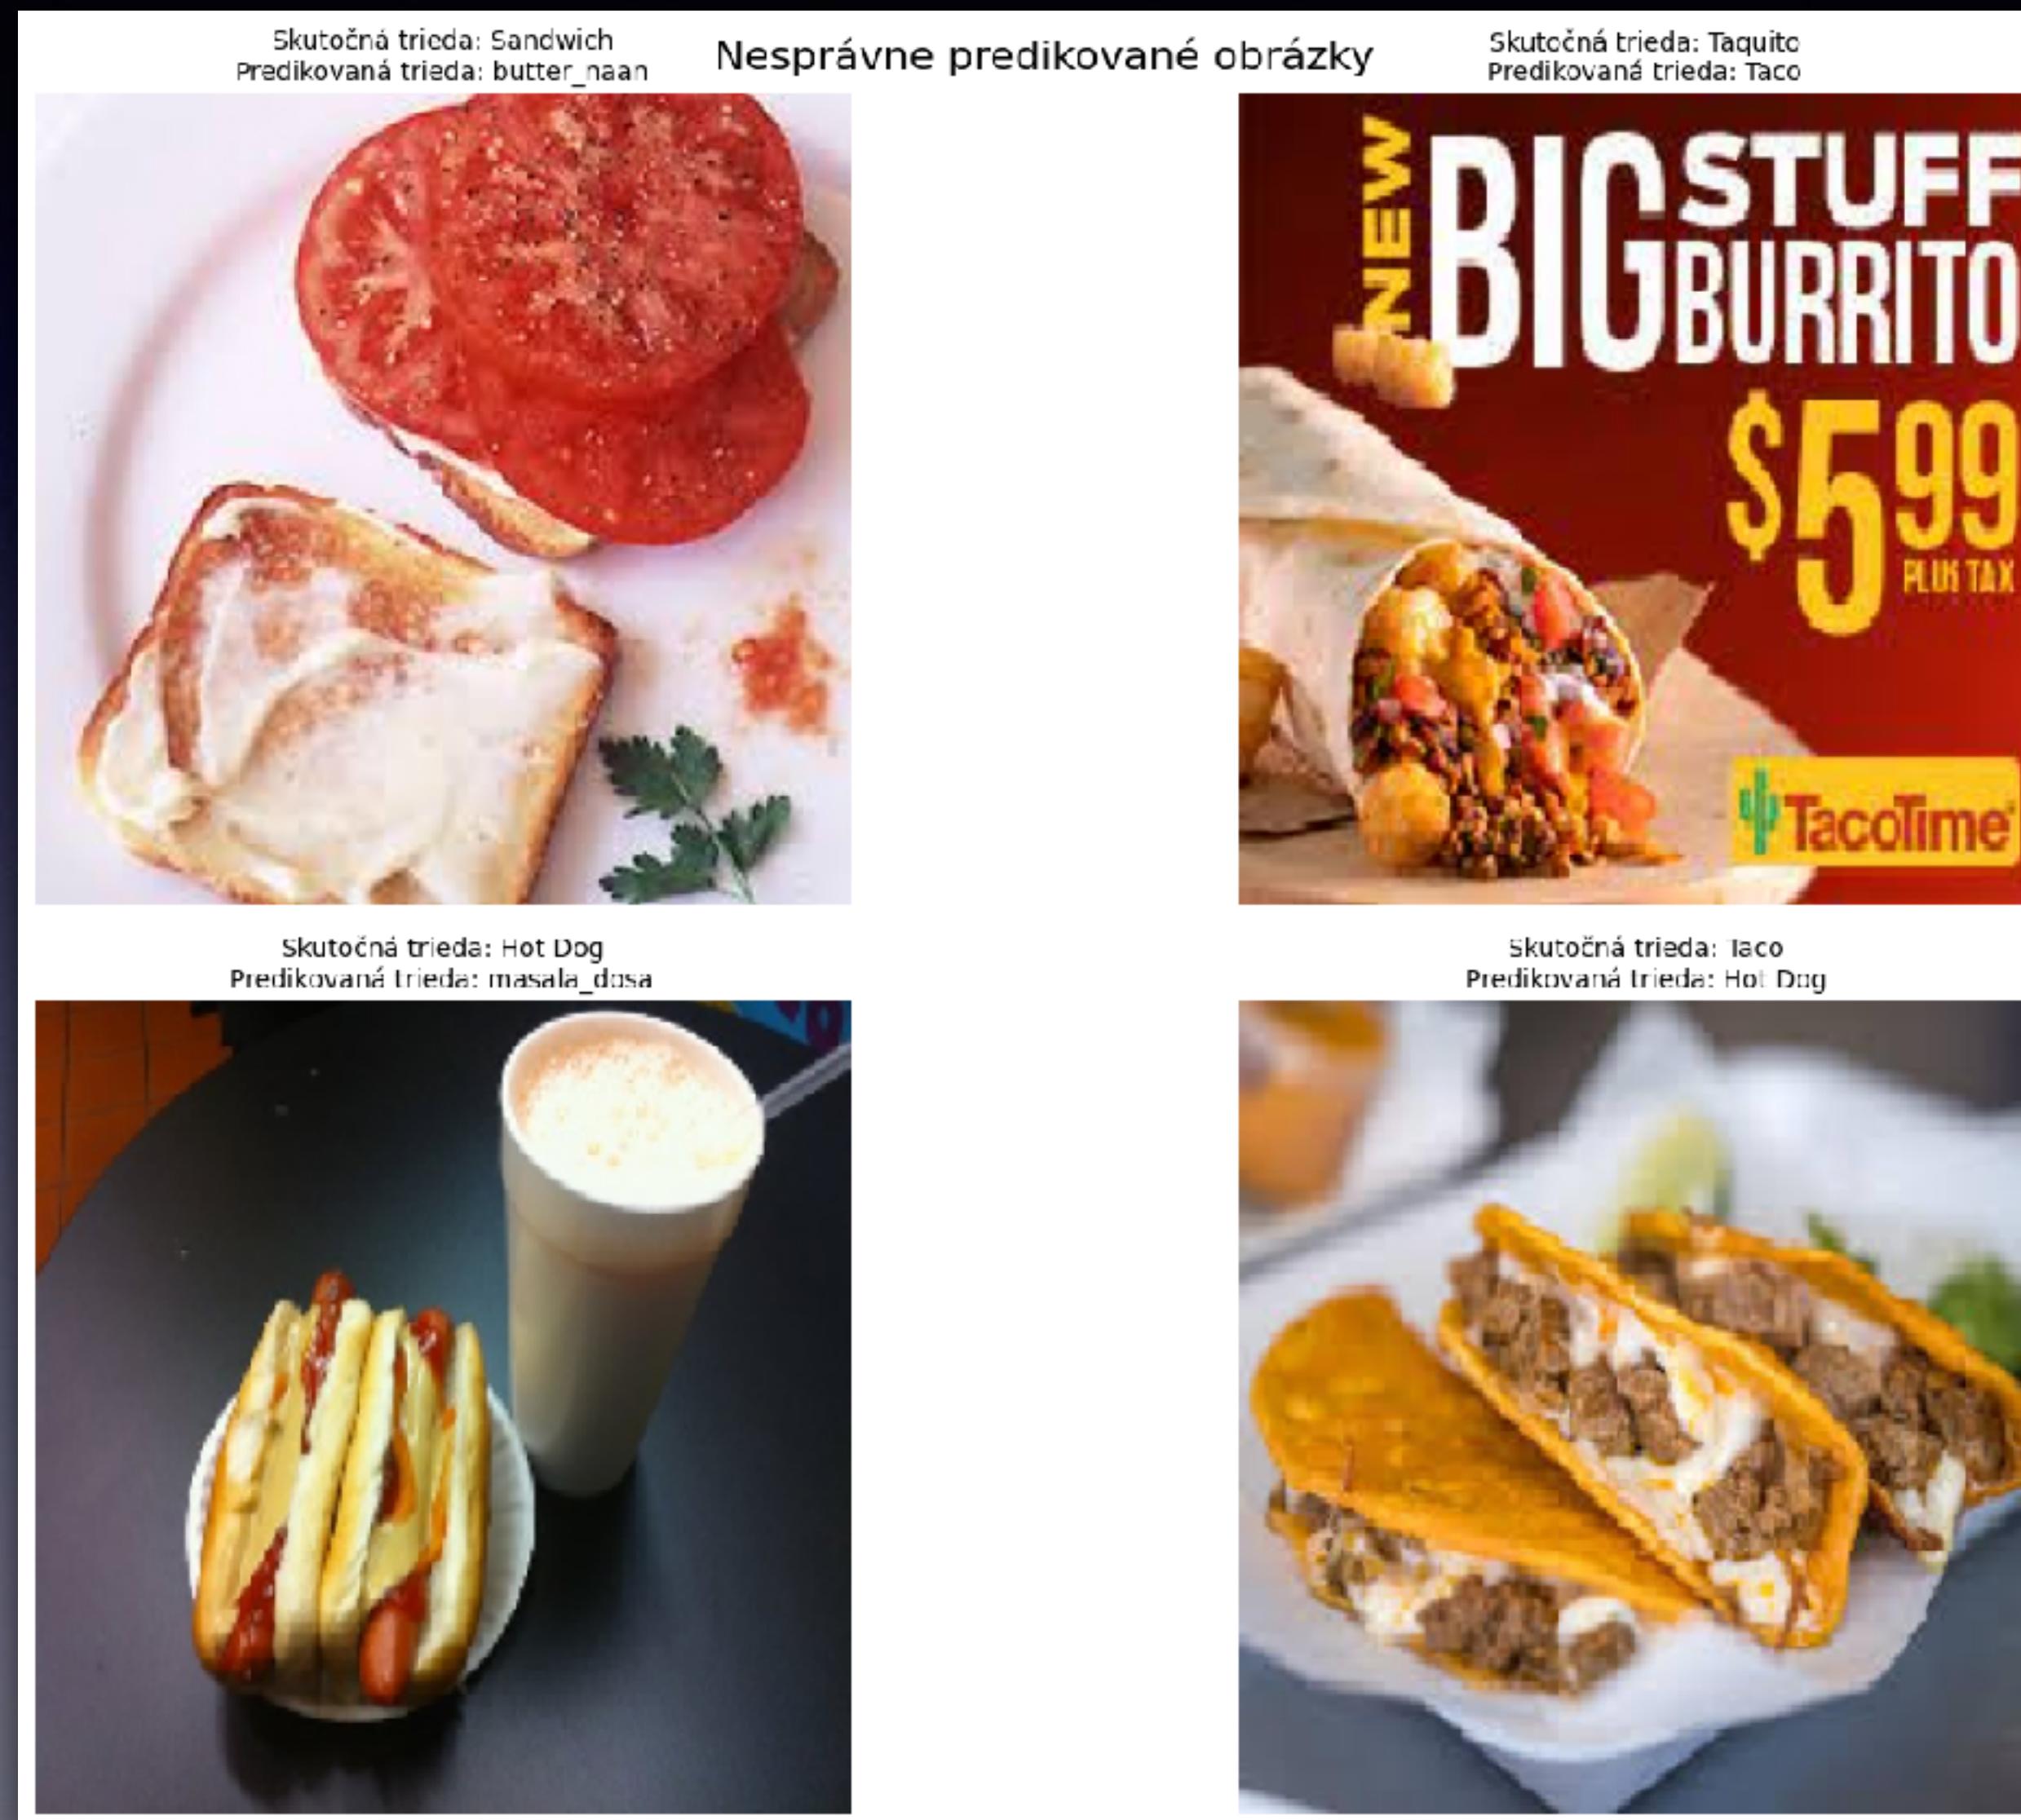


S regularizáciou

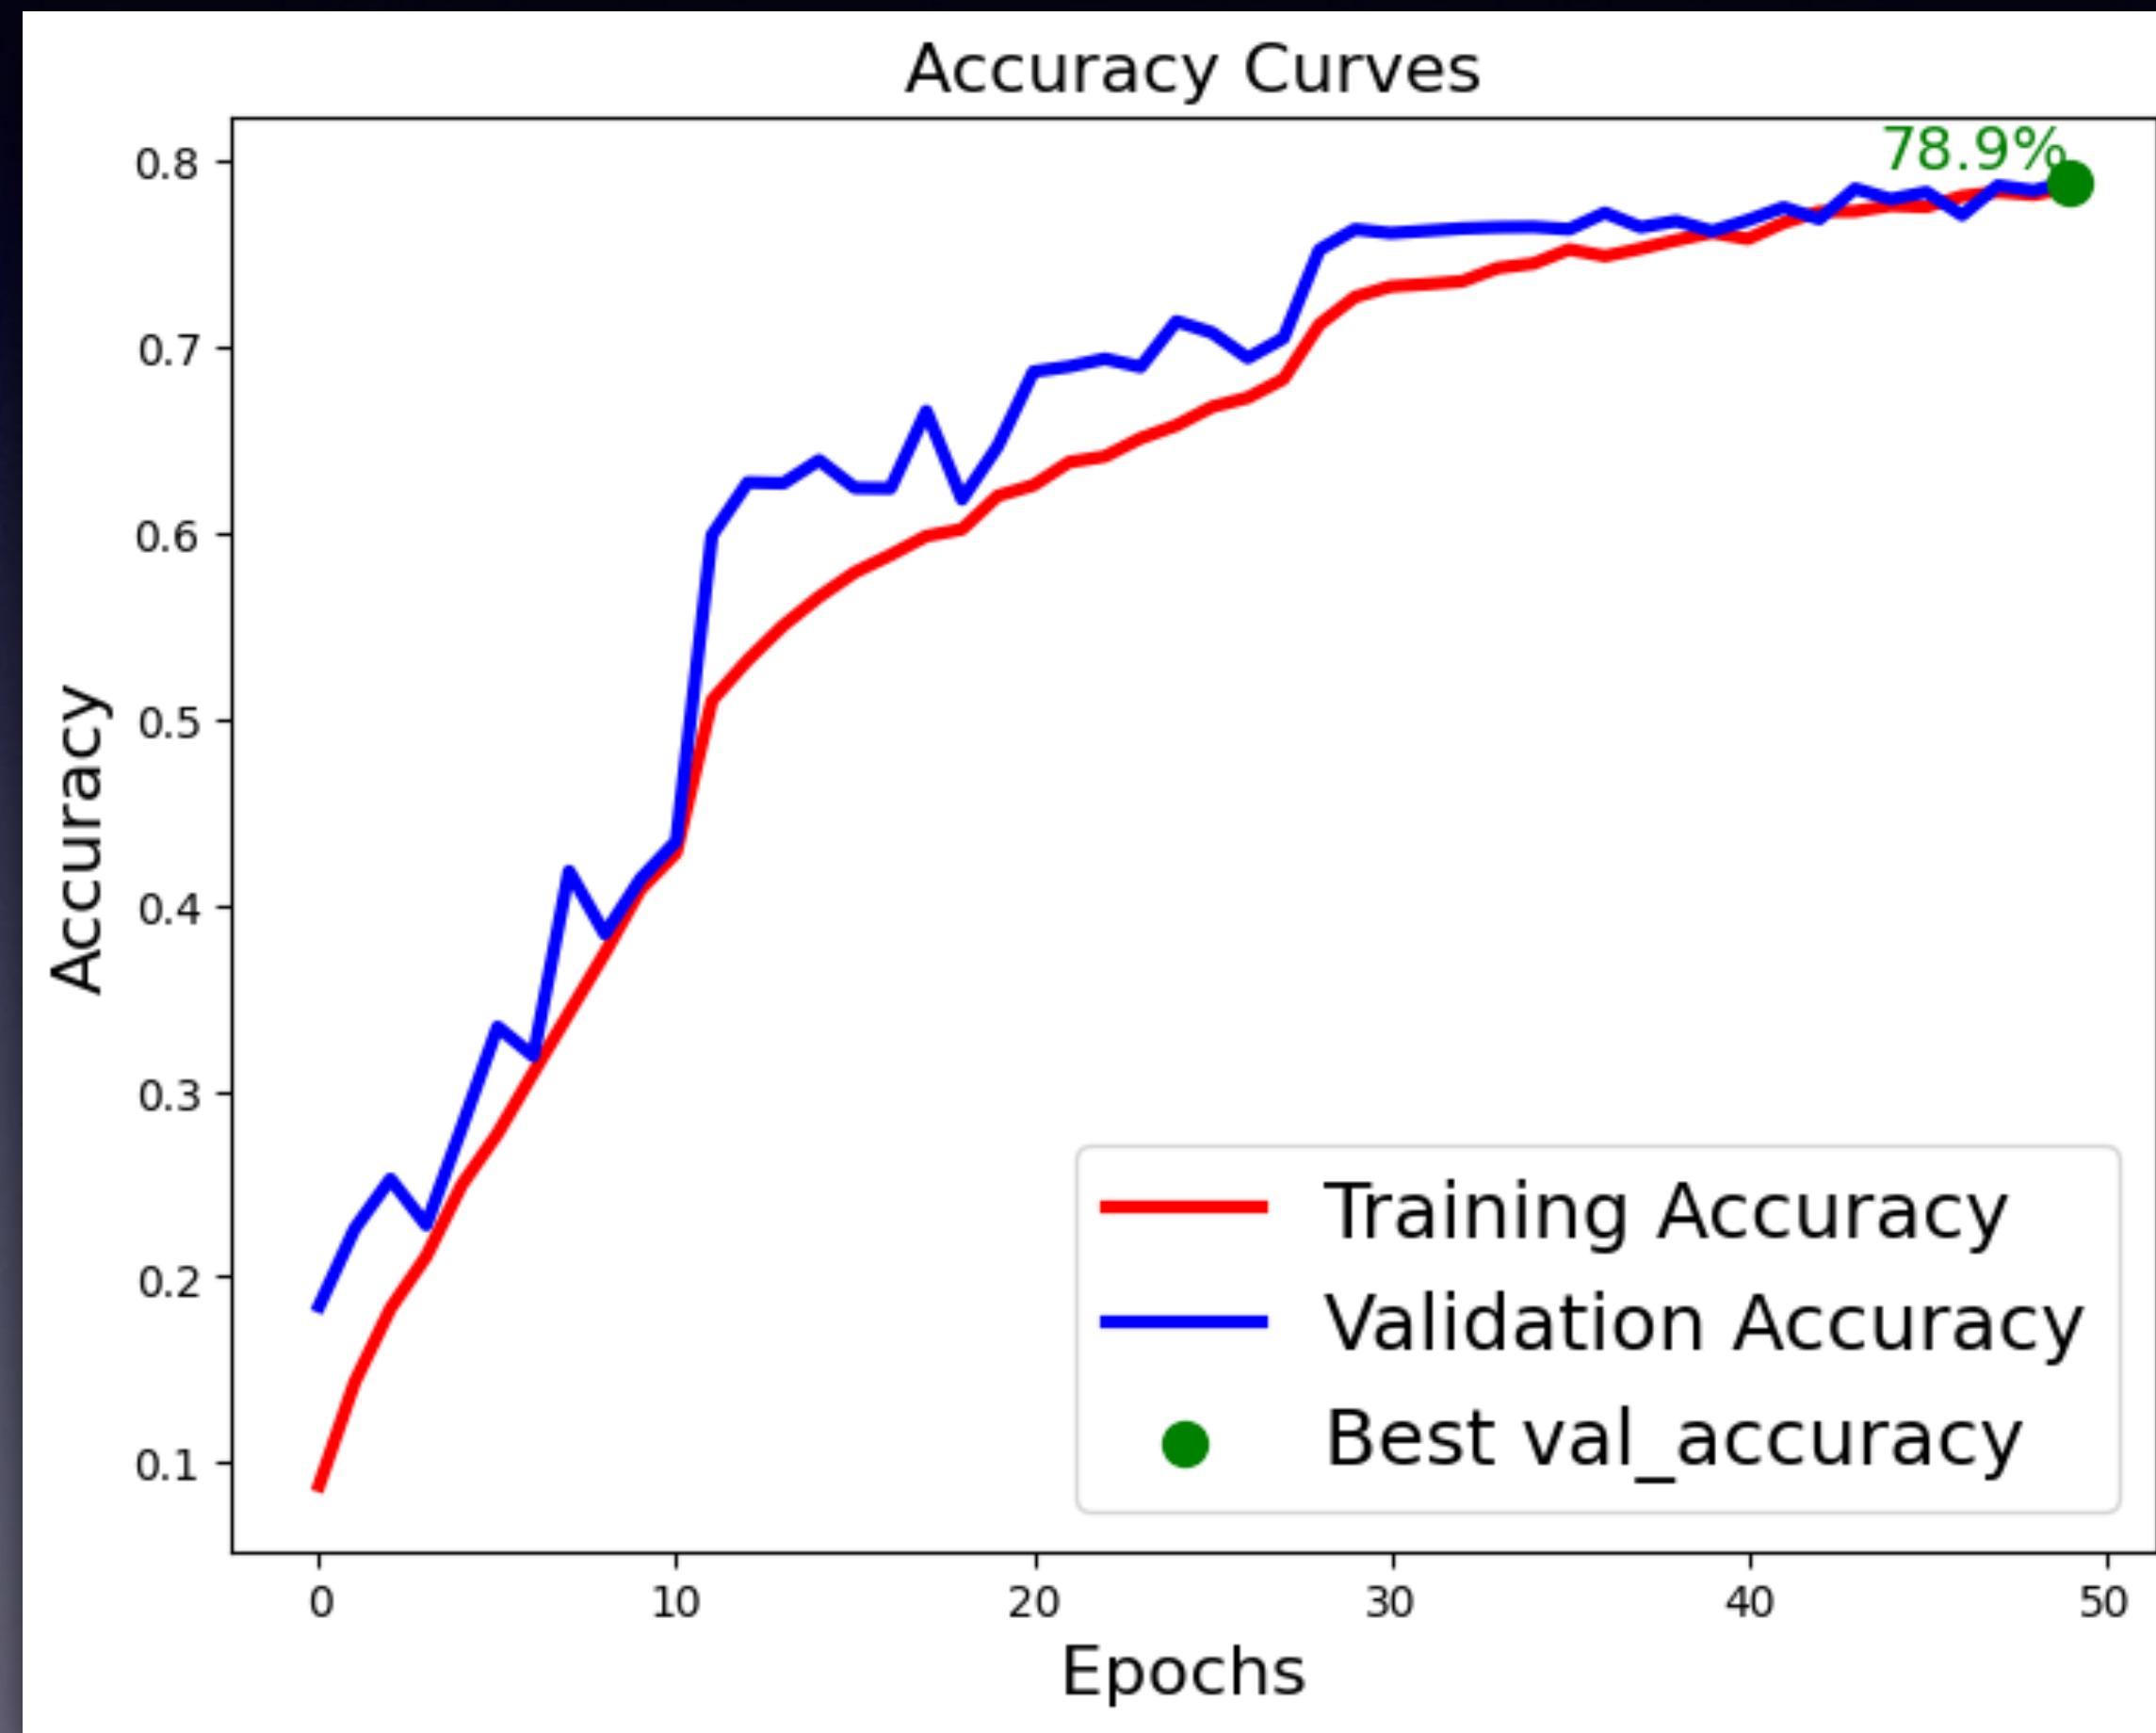
# RN502 s regularizáciou



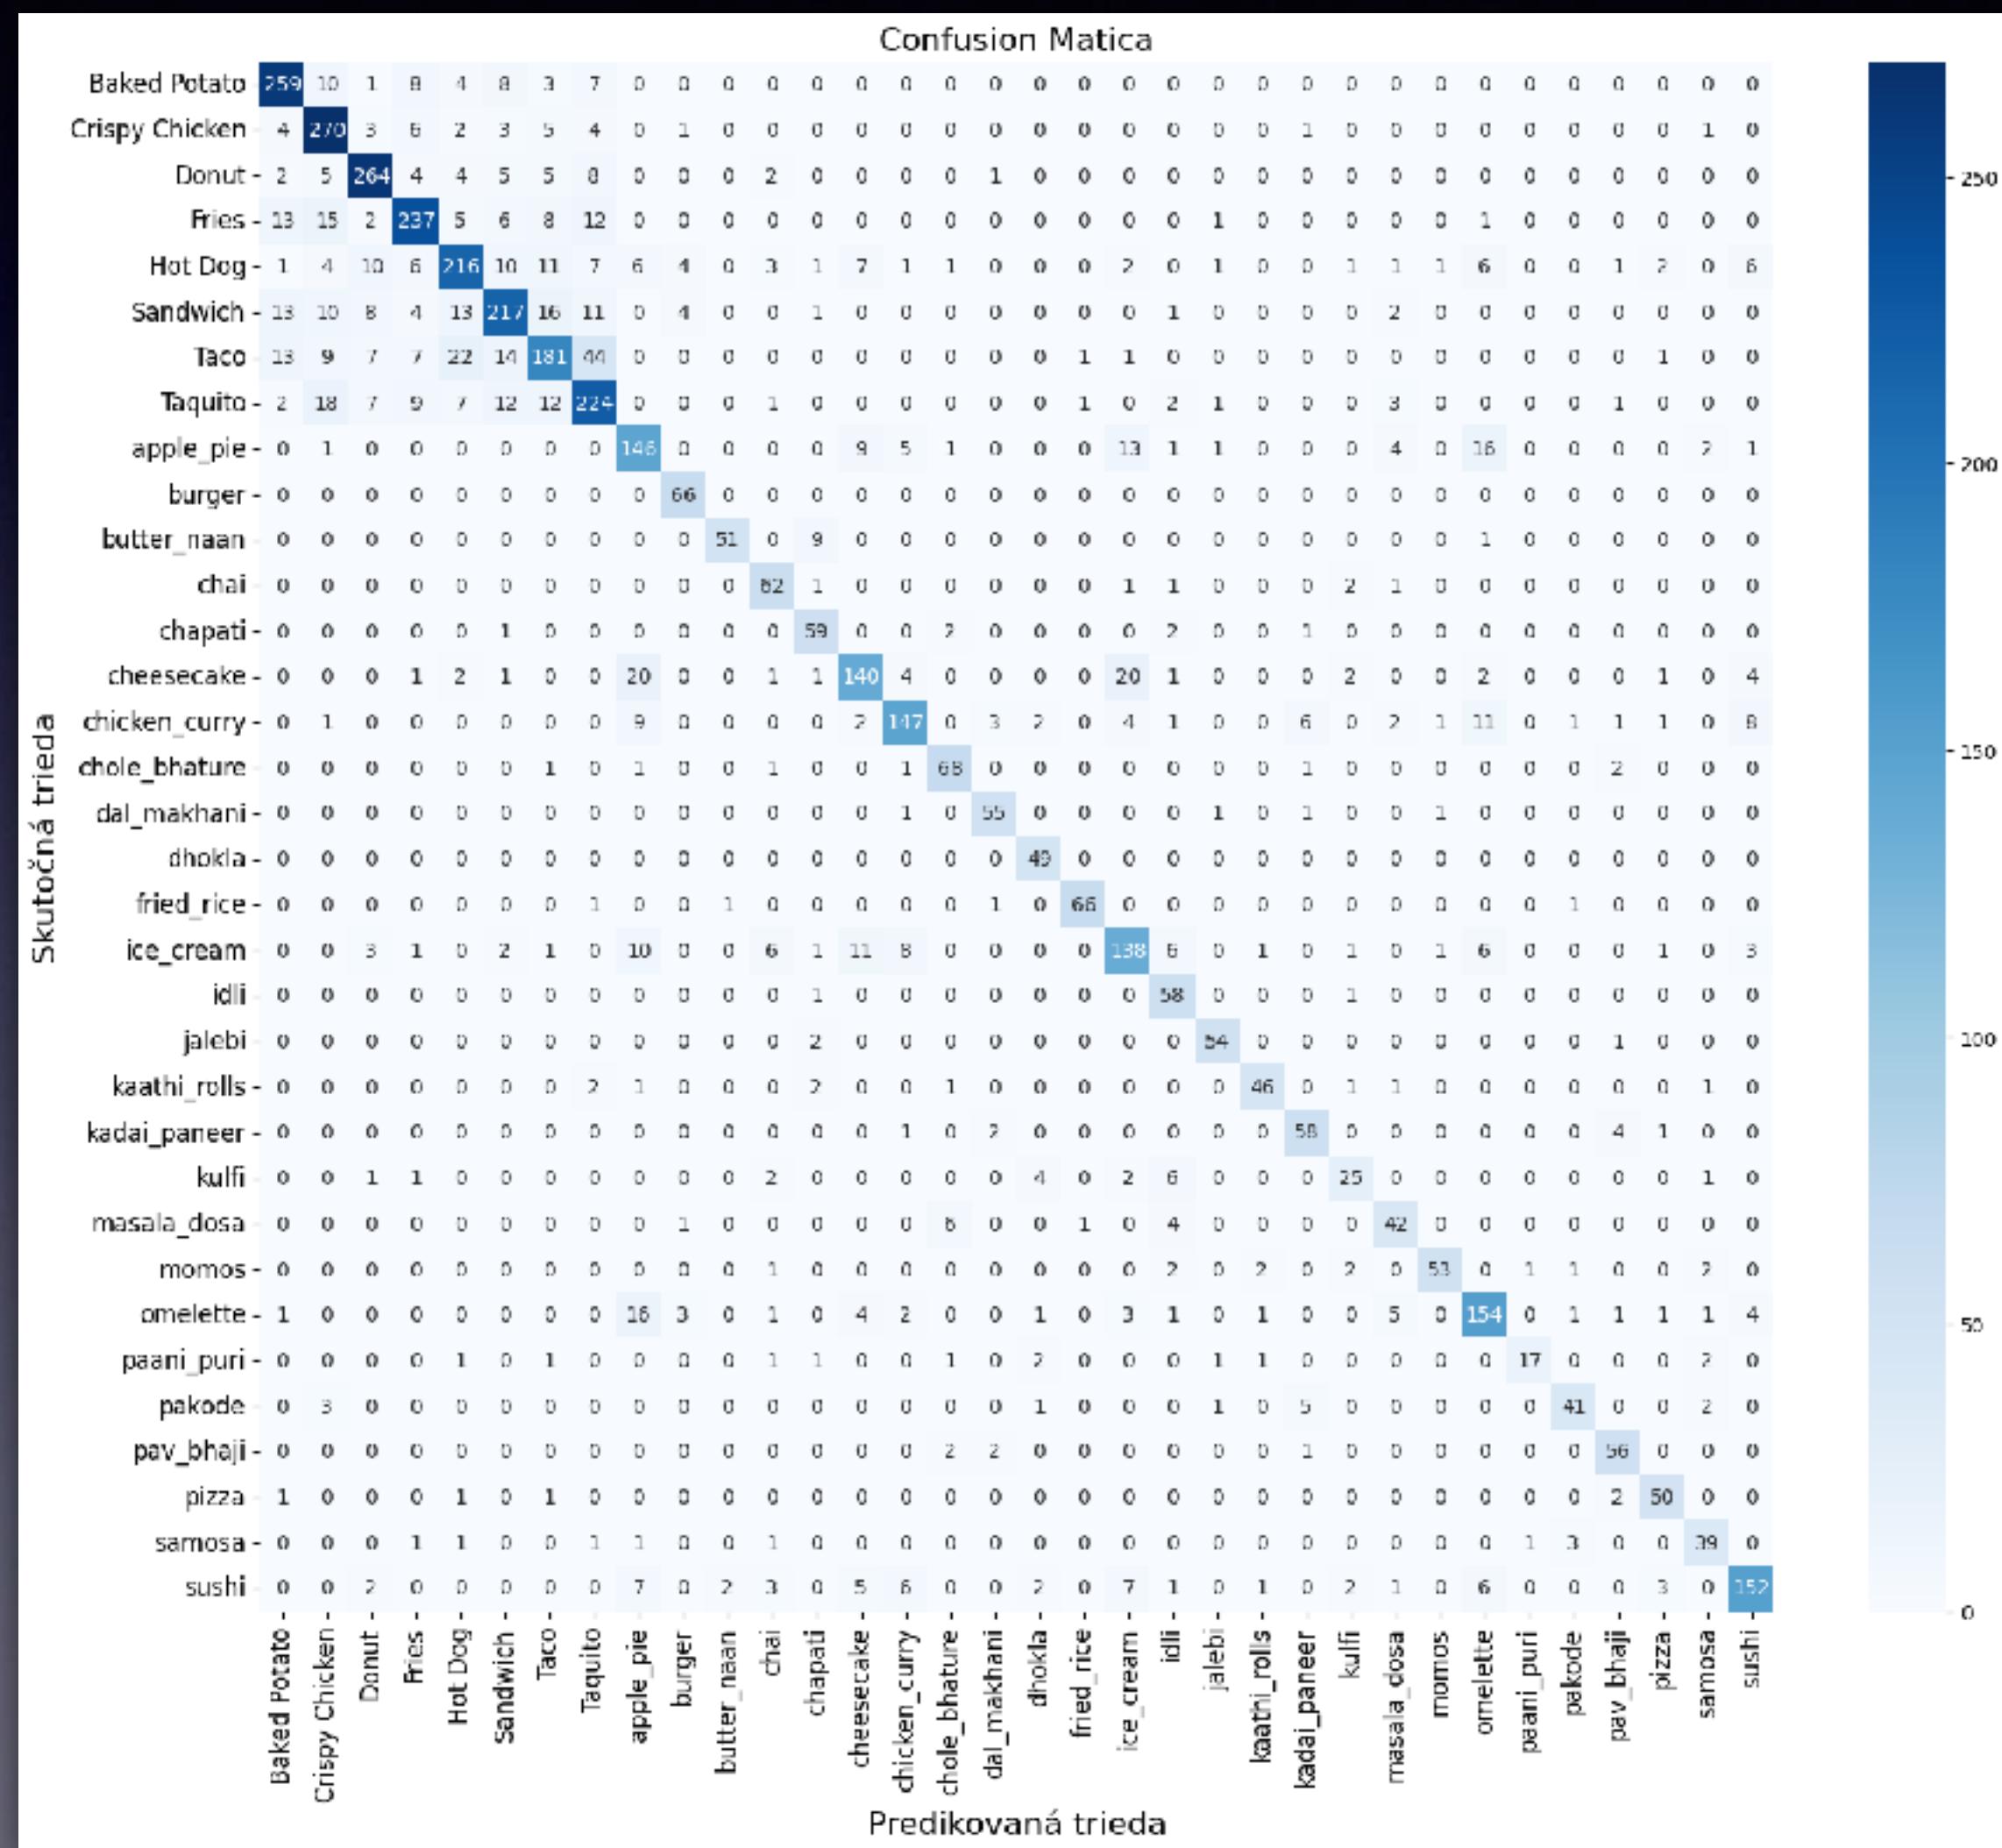
# RN502 s regularizáciou



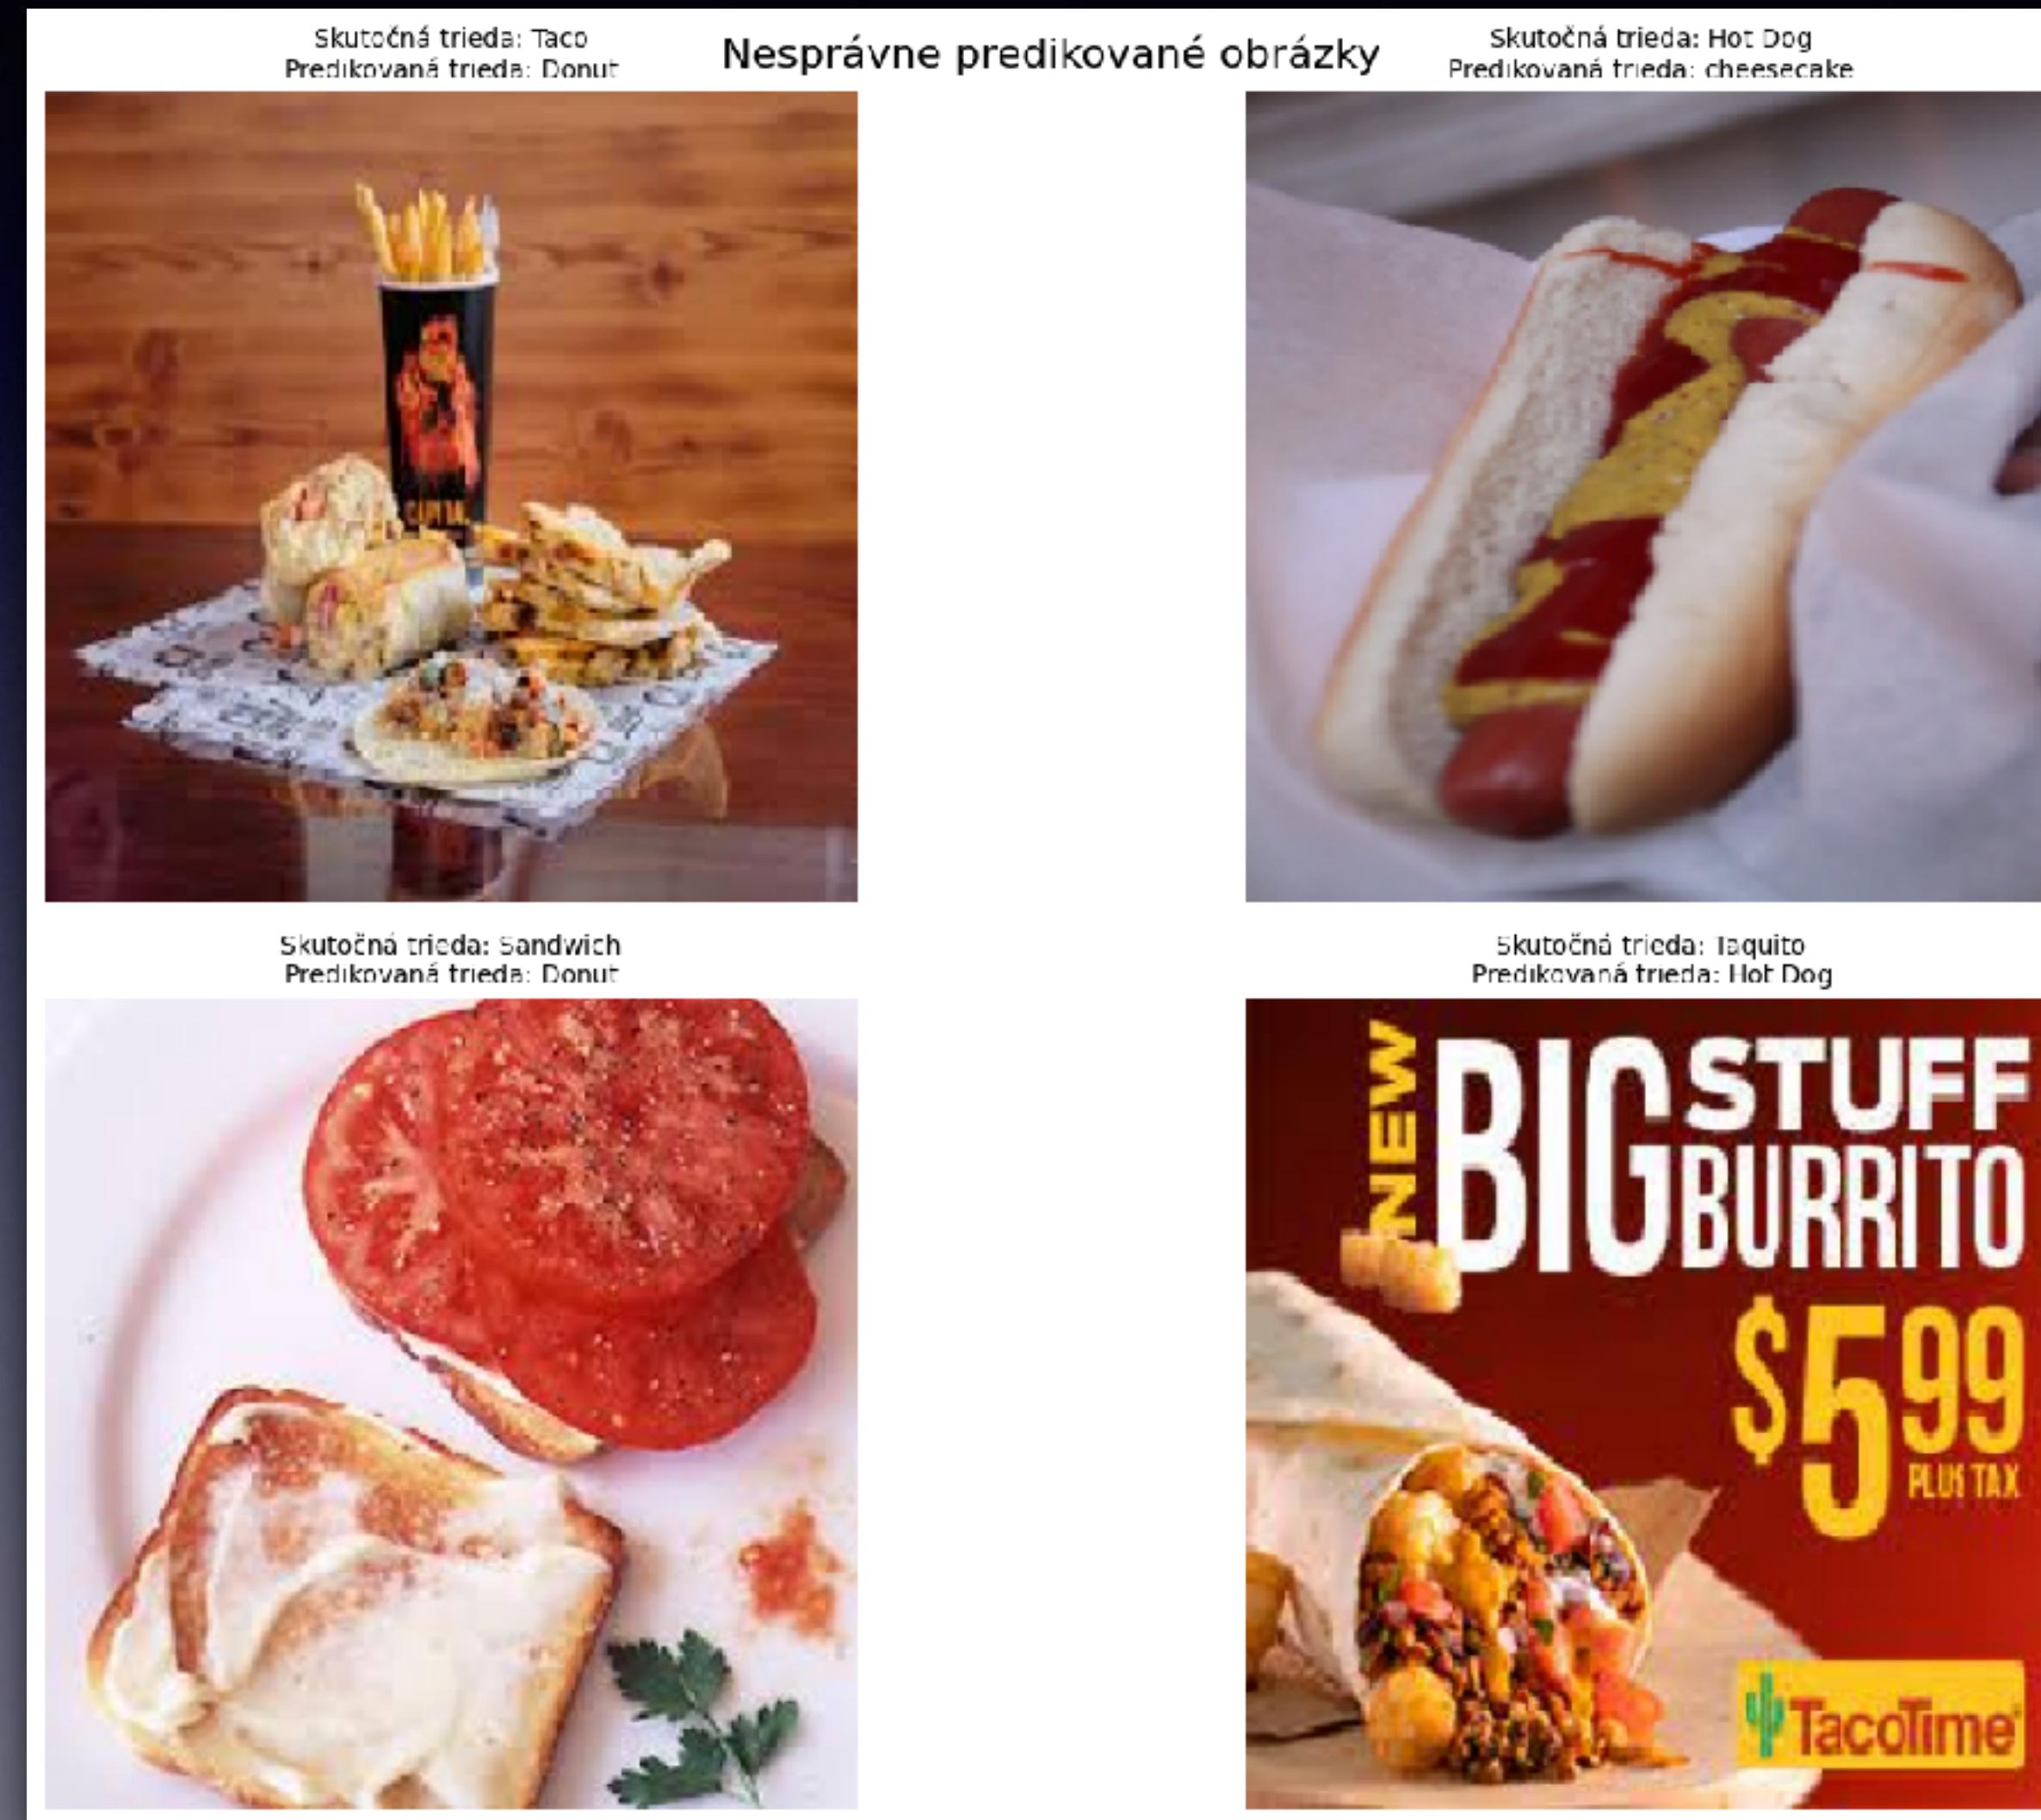
# Vlastná neurónka



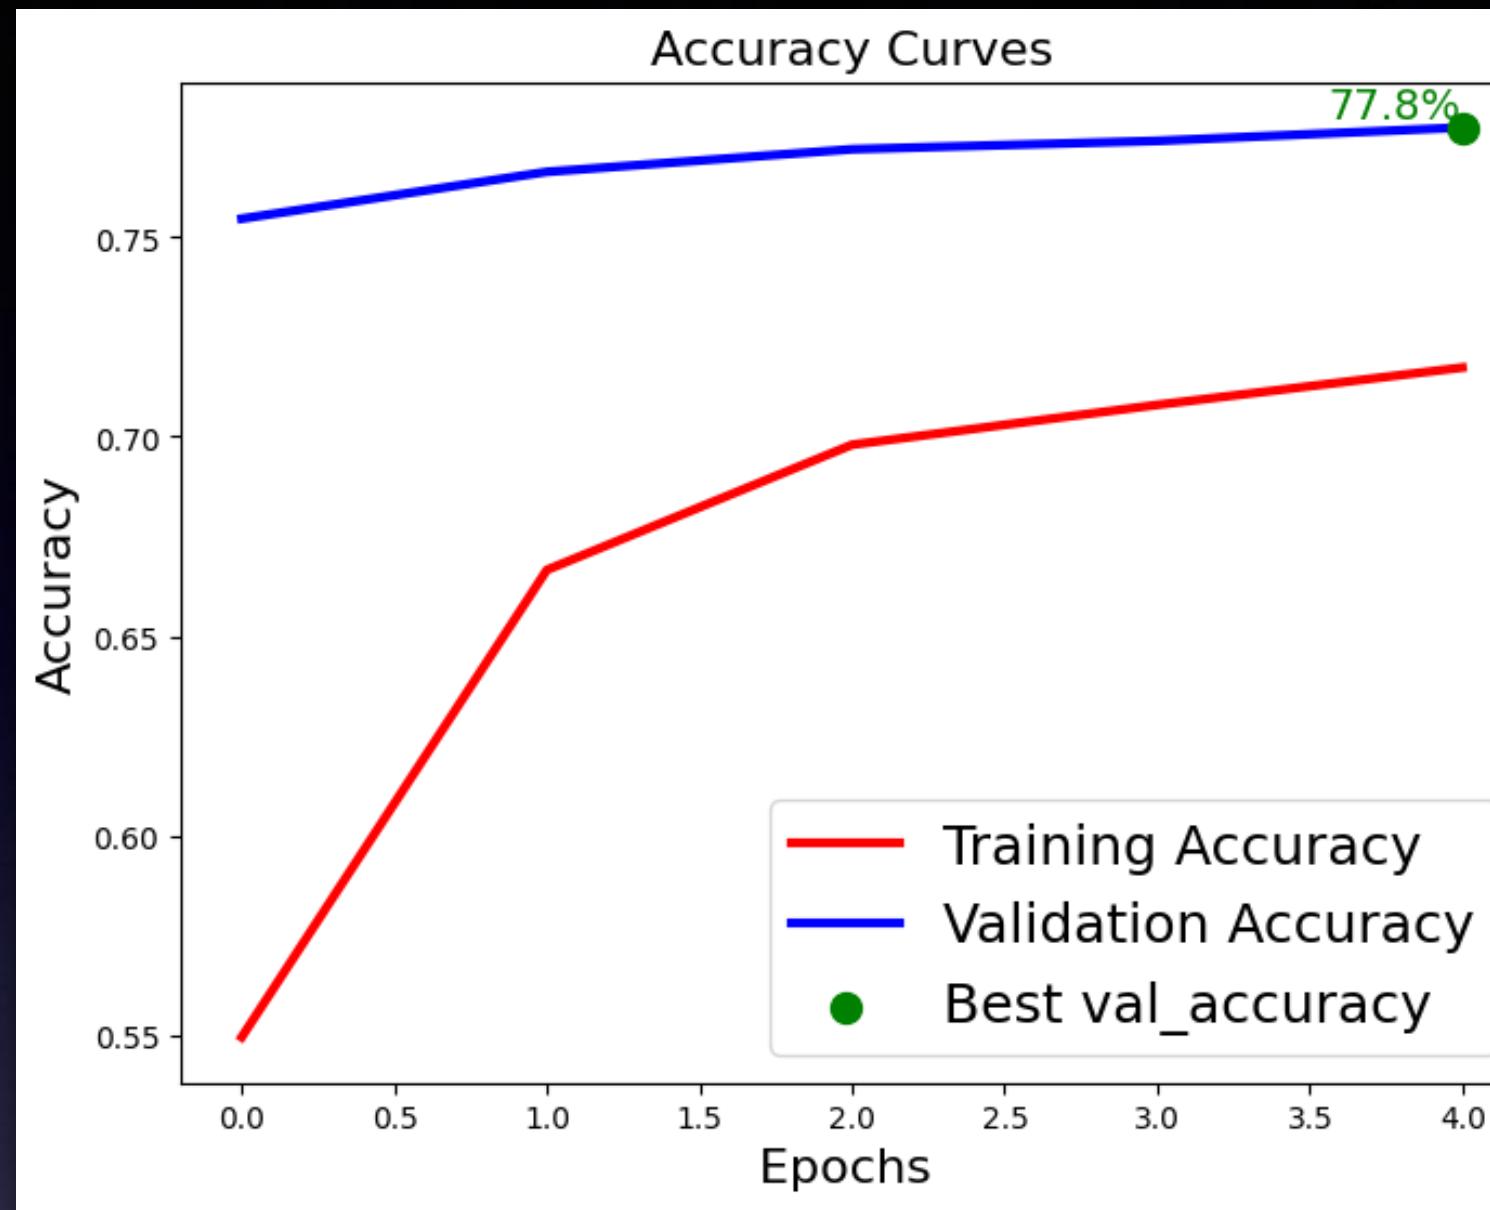
# Vlastná neurónka



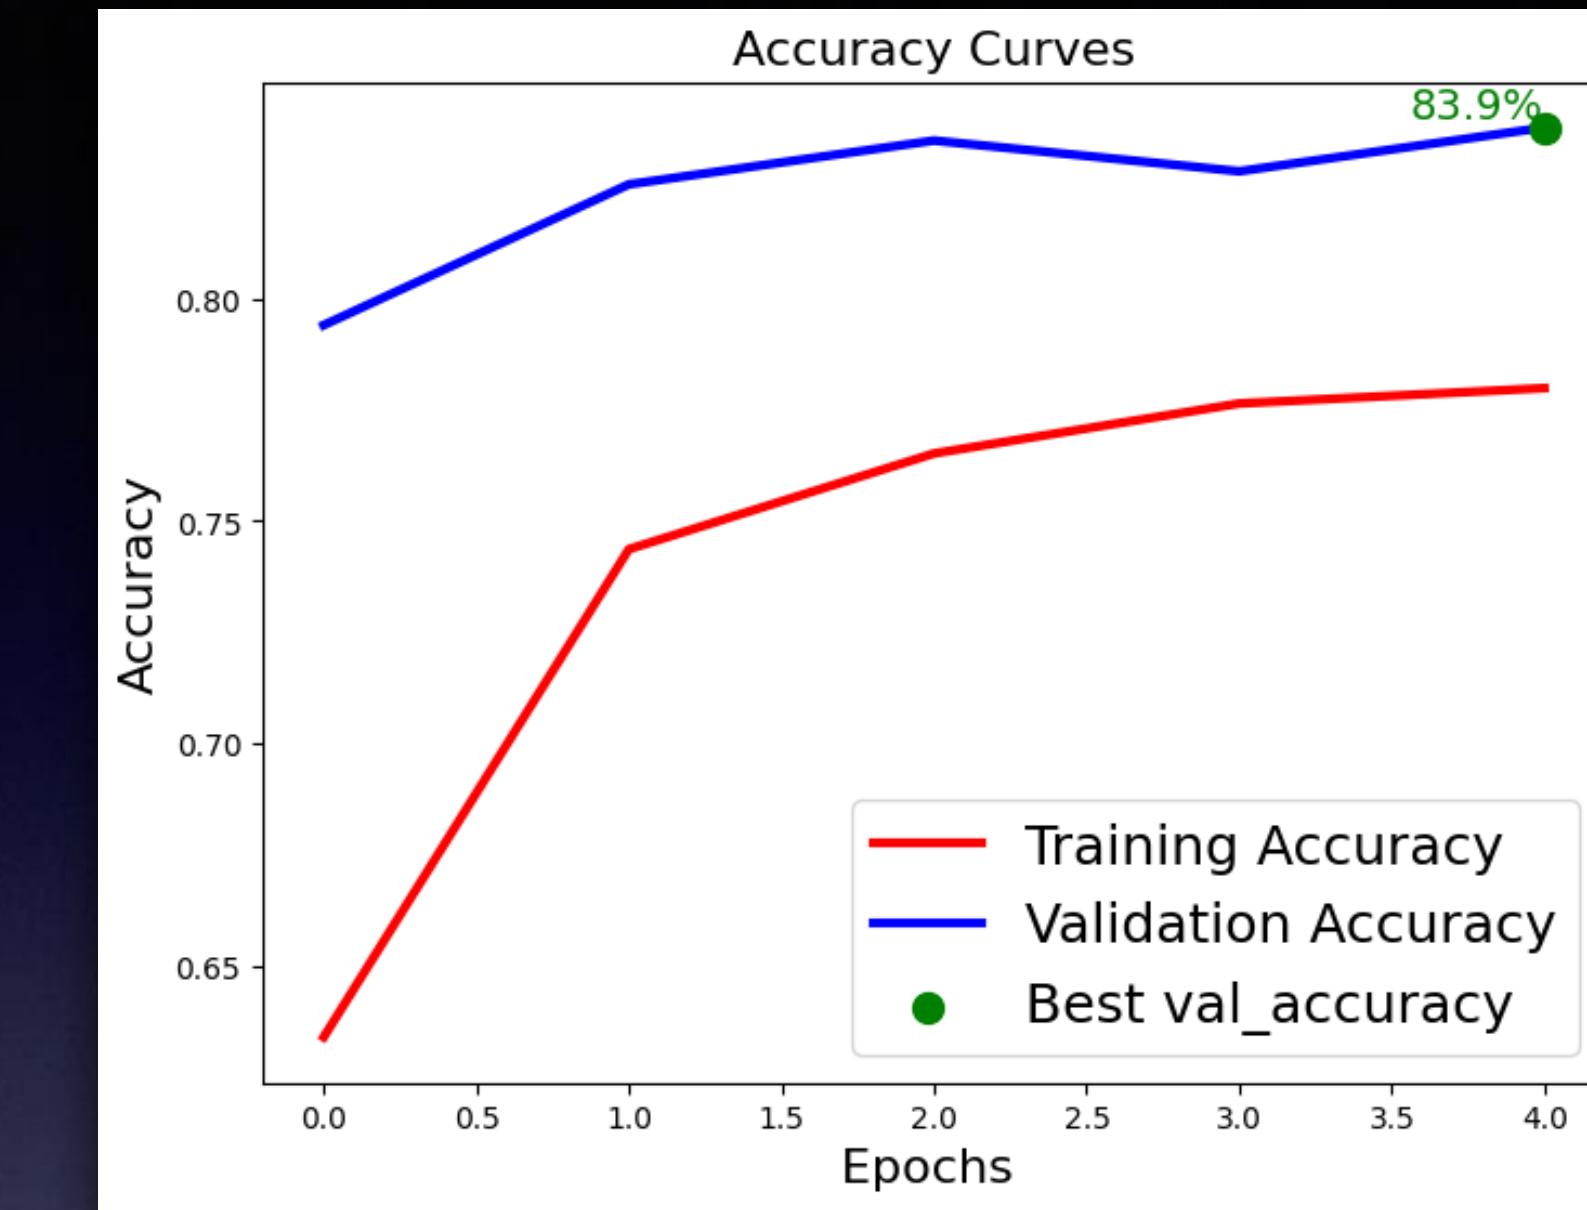
# Vlastná neurónka



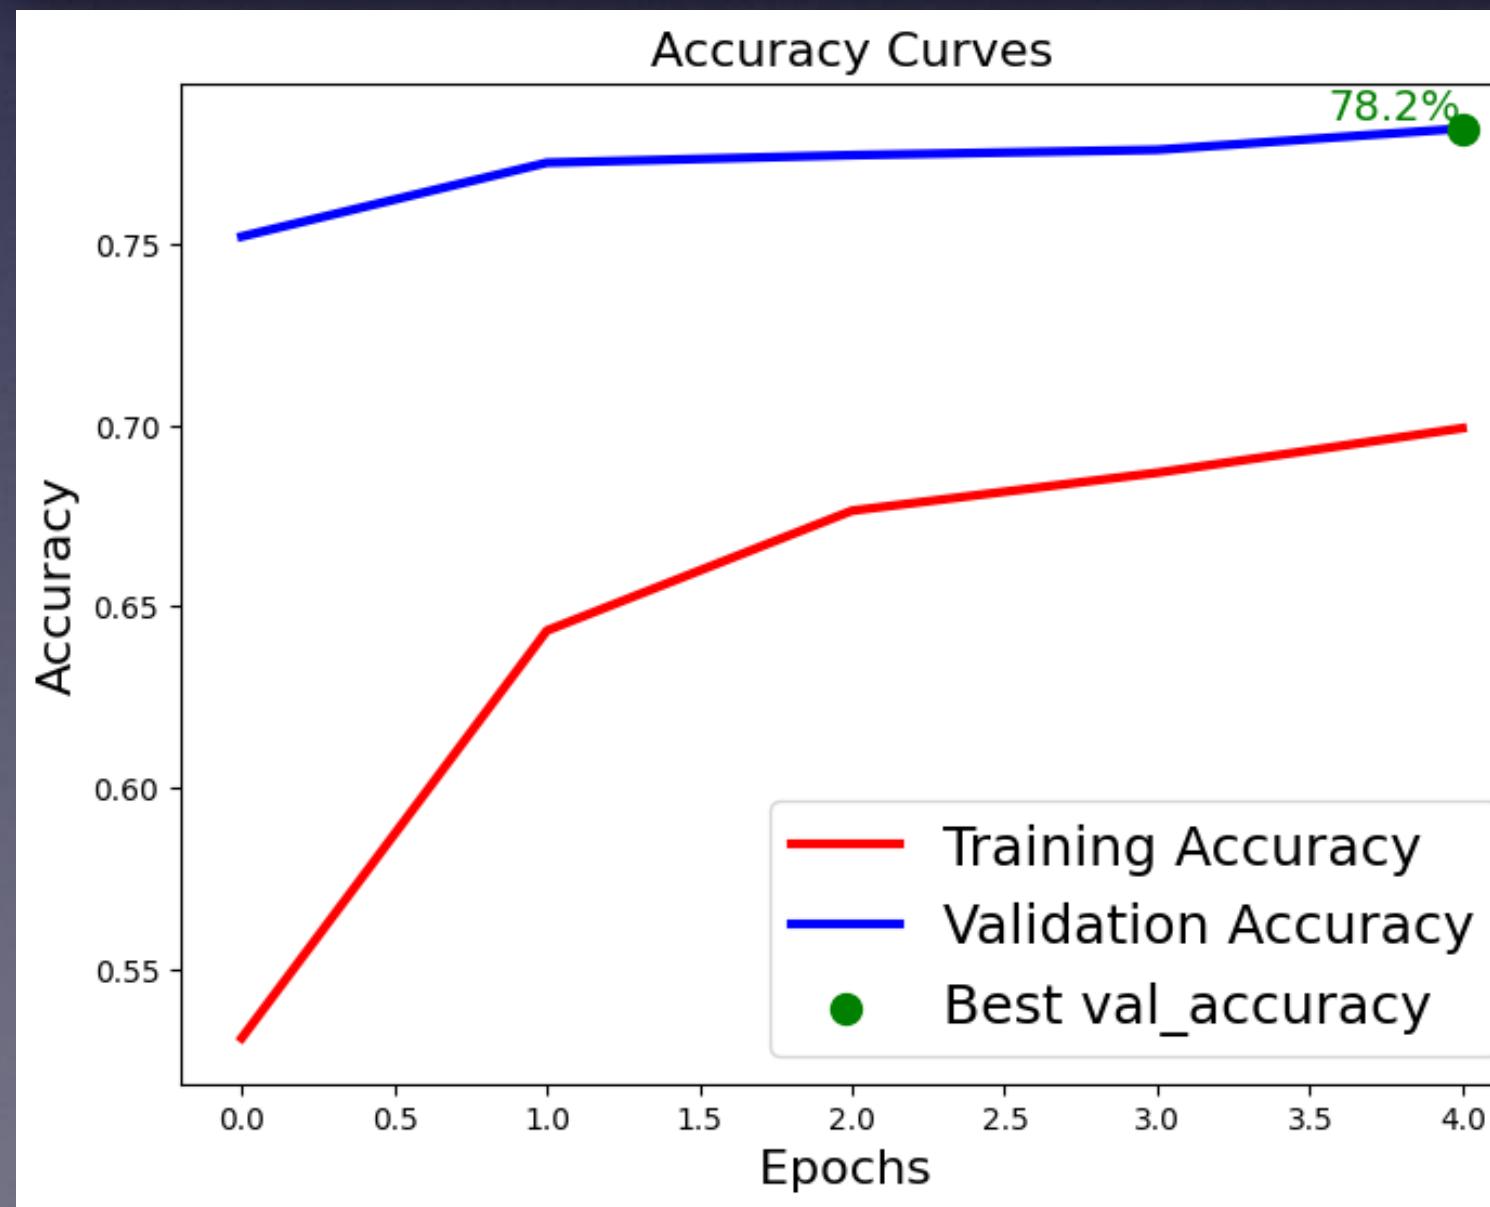
# Zhodnotenie modelov



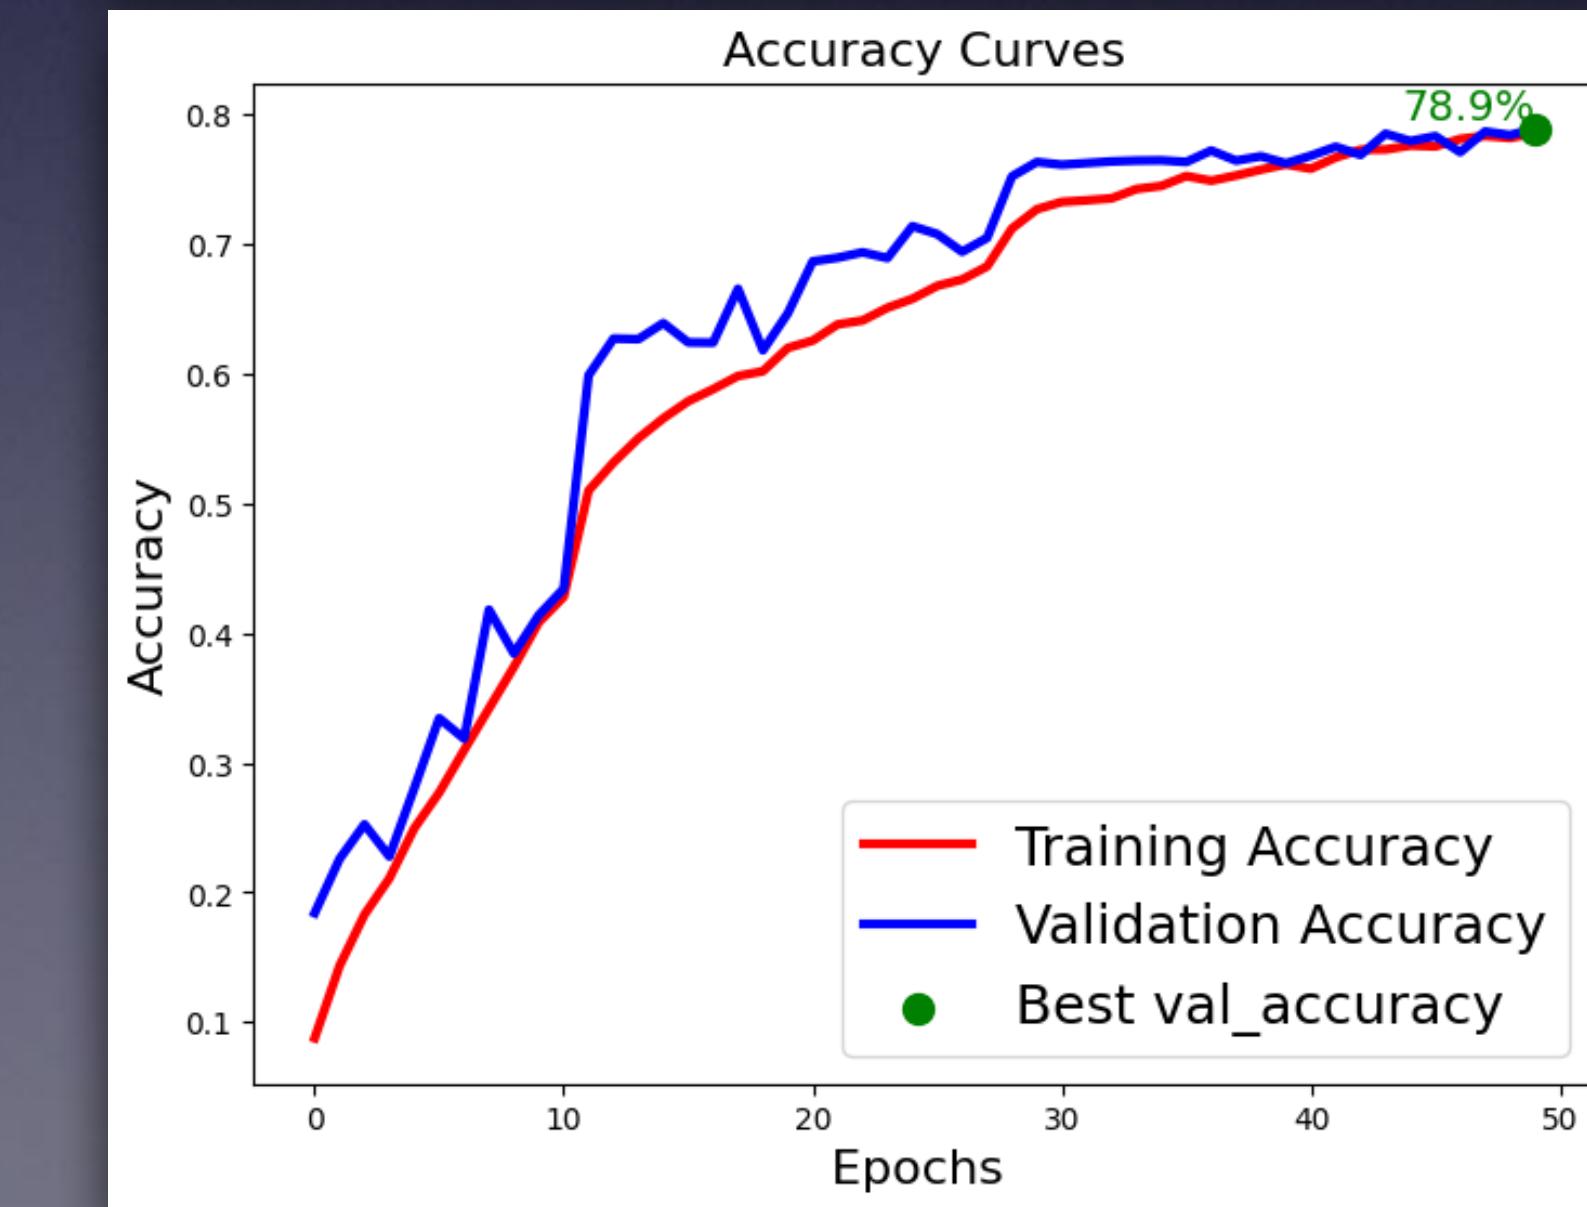
MN2R



ENB2R



RN502R



VN

# Zhodnotenie modelov

Model	Accuracy [%]	Čas konvergencie (5/30 epoch) [s]	Vel'kost' modelu (MB)
MN2R	77.8	1580	14.3
ENB2R	83.9	1983	41.2
RE502R	78.2	1758	108
VN	78.9	12685	269

# Možné vylepšenia

1. Skúsiť rozmrazit X1 posledných vrstiev modelu
2. Po tréningu finetuning na X2 vrstvách ( $X2 \ll X1$ )
3. Zmena parametrov augmentácie
4. Skúsiť zmenu aktivačnej funkcie na LeakyReLU
5. Viac epoch

Ďakujem za pozornosť'